

Durante mucho tiempo, la inteligencia artificial (IA) se basó en representaciones simbólicas, en las que el conocimiento era almacenado en reglas lógicas explícitas. En su artículo "Learning Distributed Representations of Concepts", Geoffrey Hinton propone el uso de representaciones distribuidas (RD) en redes neuronales, sentando así los bases del Deep Learning moderno.

La idea es que, en lugar de asignar un nodo único a cada concepto (como en los sistemas simbólicos), los conceptos emergen de patrones de activación en múltiples unidades, lo que permite capturar relaciones entre conceptos de forma más flexible y eficiente. Con esto entonces, y a diferencia de las representaciones simbólicas clásicas, las RD facilitan la generalización y el aprendizaje a partir de ejemplos.

Un par de limitaciones de la IA simbólica pueden ser su rigidez y problemas para manejar variabilidad y ambigüedad. Las RD entonces superan estos problemas al permitir flexibilidad a las redes neuronales, lo que permite aprendizaje y adaptabilidad a nuevos datos sin tener que redefinir reglas manualmente.

En su estudio, Hinton emplea redes neuronales entrenadas con "backpropagation" para aprender relaciones de parentesco en árboles genealógicos. La red aprende a representar las relaciones familiares en un espacio de alta dimensión, lo que demuestra que las RD pueden captar estructuras subyacentes en los datos sin estar explícitamente programados.

Tecnologías como el procesamiento de lenguaje natural, visión por computadora y los embeddings de palabras son aplicaciones directas de esta idea. Sin embargo, a pesar de su capacidad, las RD pueden ser opacas y difíciles de interpretar, además que requieren muchísimos datos y recursos computacionales para su entrenamiento, lo que sigue siendo un desafío a día de hoy.