

Reconstrucción Angular y Clasificación de Rayos Cósmicos

OBSERVATORIO CONDOR

LUIS F. NAVARRO

LICENCIADO EN FÍSICA
ESTUDIANTE MAGÍSTER ING. INFORMÁTICA

12 DE JUNIO DE 2025

INF-577
REDES NEURONALES Y DEEP LEARNING AVANZADO



Contenidos

3 El observatorio
CONDOR

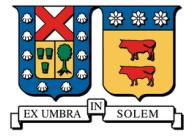
4 Rayos cósmicos y
duchas de partículas

5 CORSIKA Software,
Simulaciones CONDOR y
procesamiento de datos

6 Arquitecturas de Deep
Learning para predicciones

7 Resultados
experimentales

9 Conclusiones



El Observatorio CONDOR

Ubicado en Atacama, apunta a ser el observatorio de rayos cósmicos de mayor altitud del planeta (~5600 metros a.s.l) [1].

Detectará fenómenos transitorios como estallidos de rayos gamma.

Puente entre telescopios terrestres y satelitales.

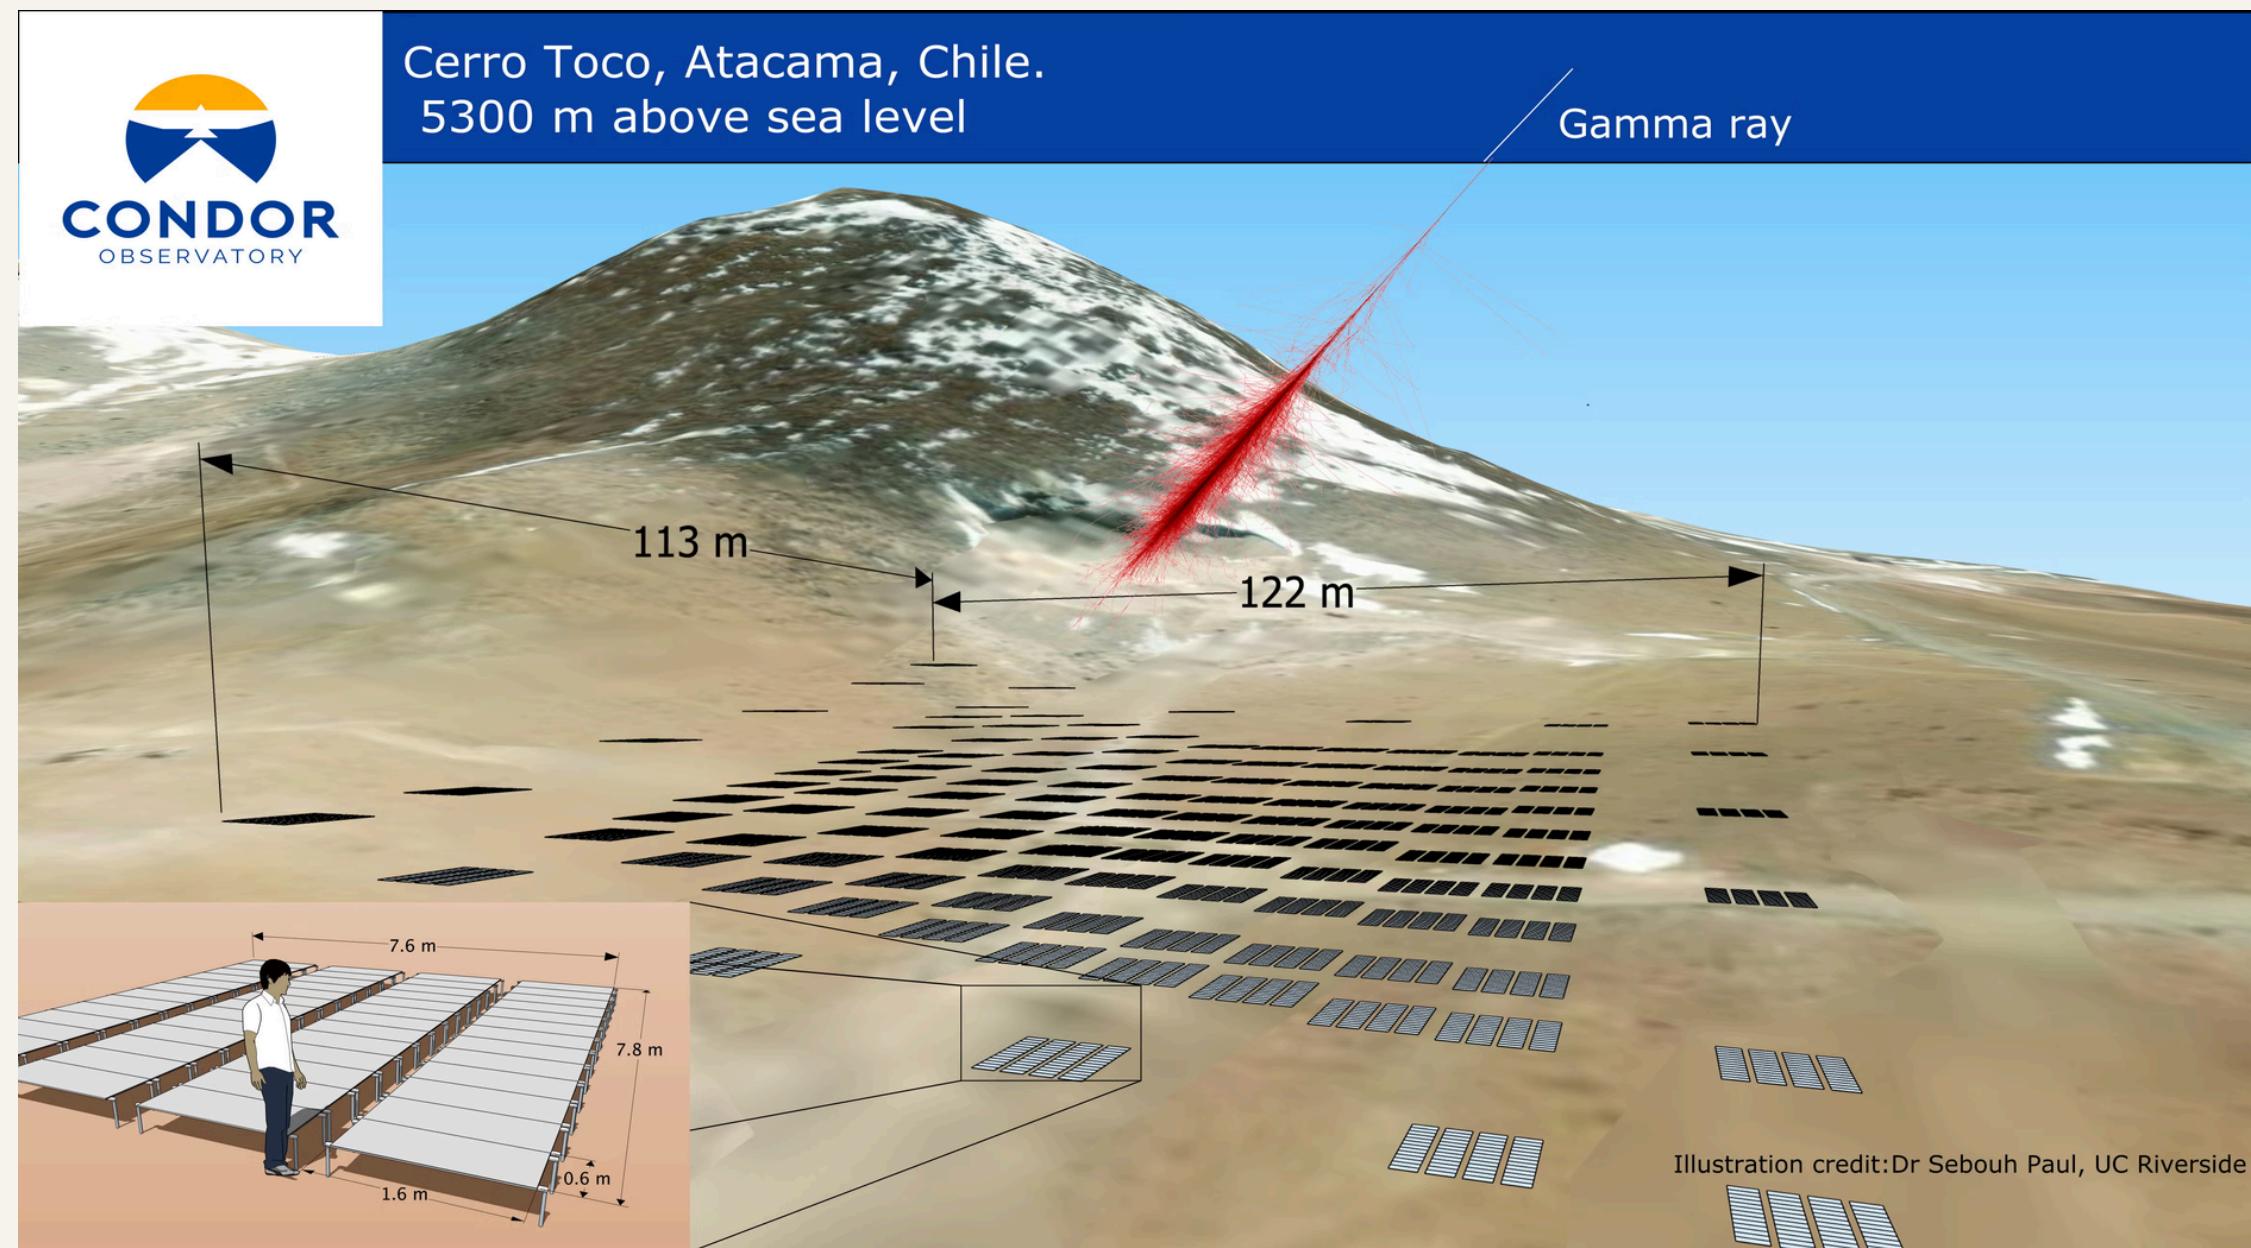


Figura 1. Representación esquemática del Observatorio CONDOR.

Rayos Cósmicos y EAS

Cuando un rayo cósmico impacta a la Tierra, éste interactúa con su atmósfera, generando partículas secundarias y, eventualmente, una ducha de partículas (EAS) [2].

CONDOR detectará EAS continuamente para comprender el comportamiento de los rayos cósmicos.

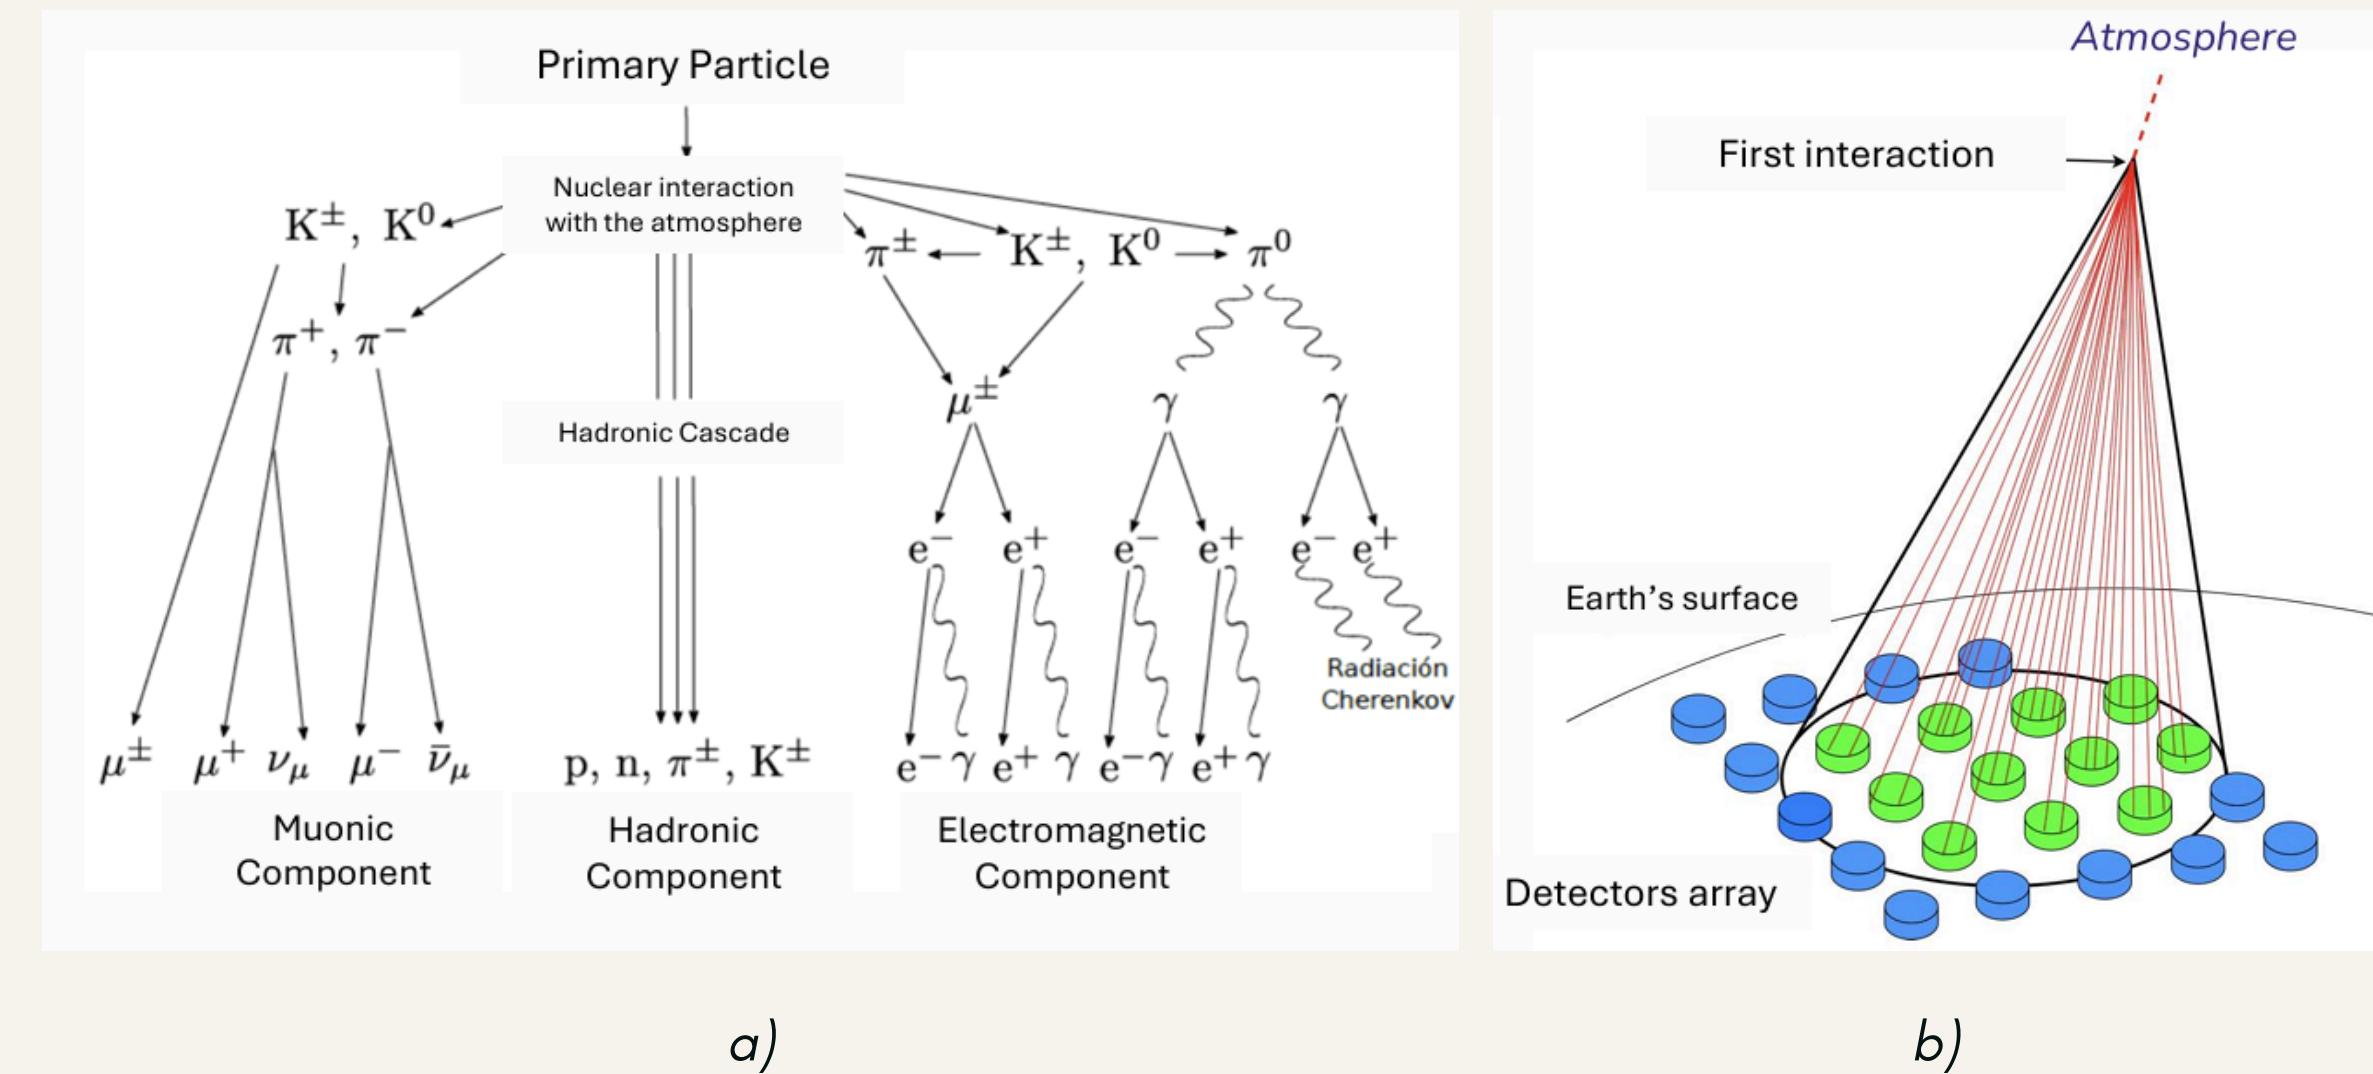
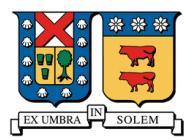


Figura 2. a) Diagrama de los componentes de una EAS generadas por una partícula primaria
b) Esquema de detección de EAS a través de arreglos terrestres.



Detección de EAS

Para lograr la detección de EAS, CONDOR constituirá un arreglo de detectores basados en plásticos centelladores, que capturarán las partículas secundarias generadas por los rayos cósmicos.

Estas detecciones serán la fuente para predecir la **trayectoria** y **partícula** que las generó.

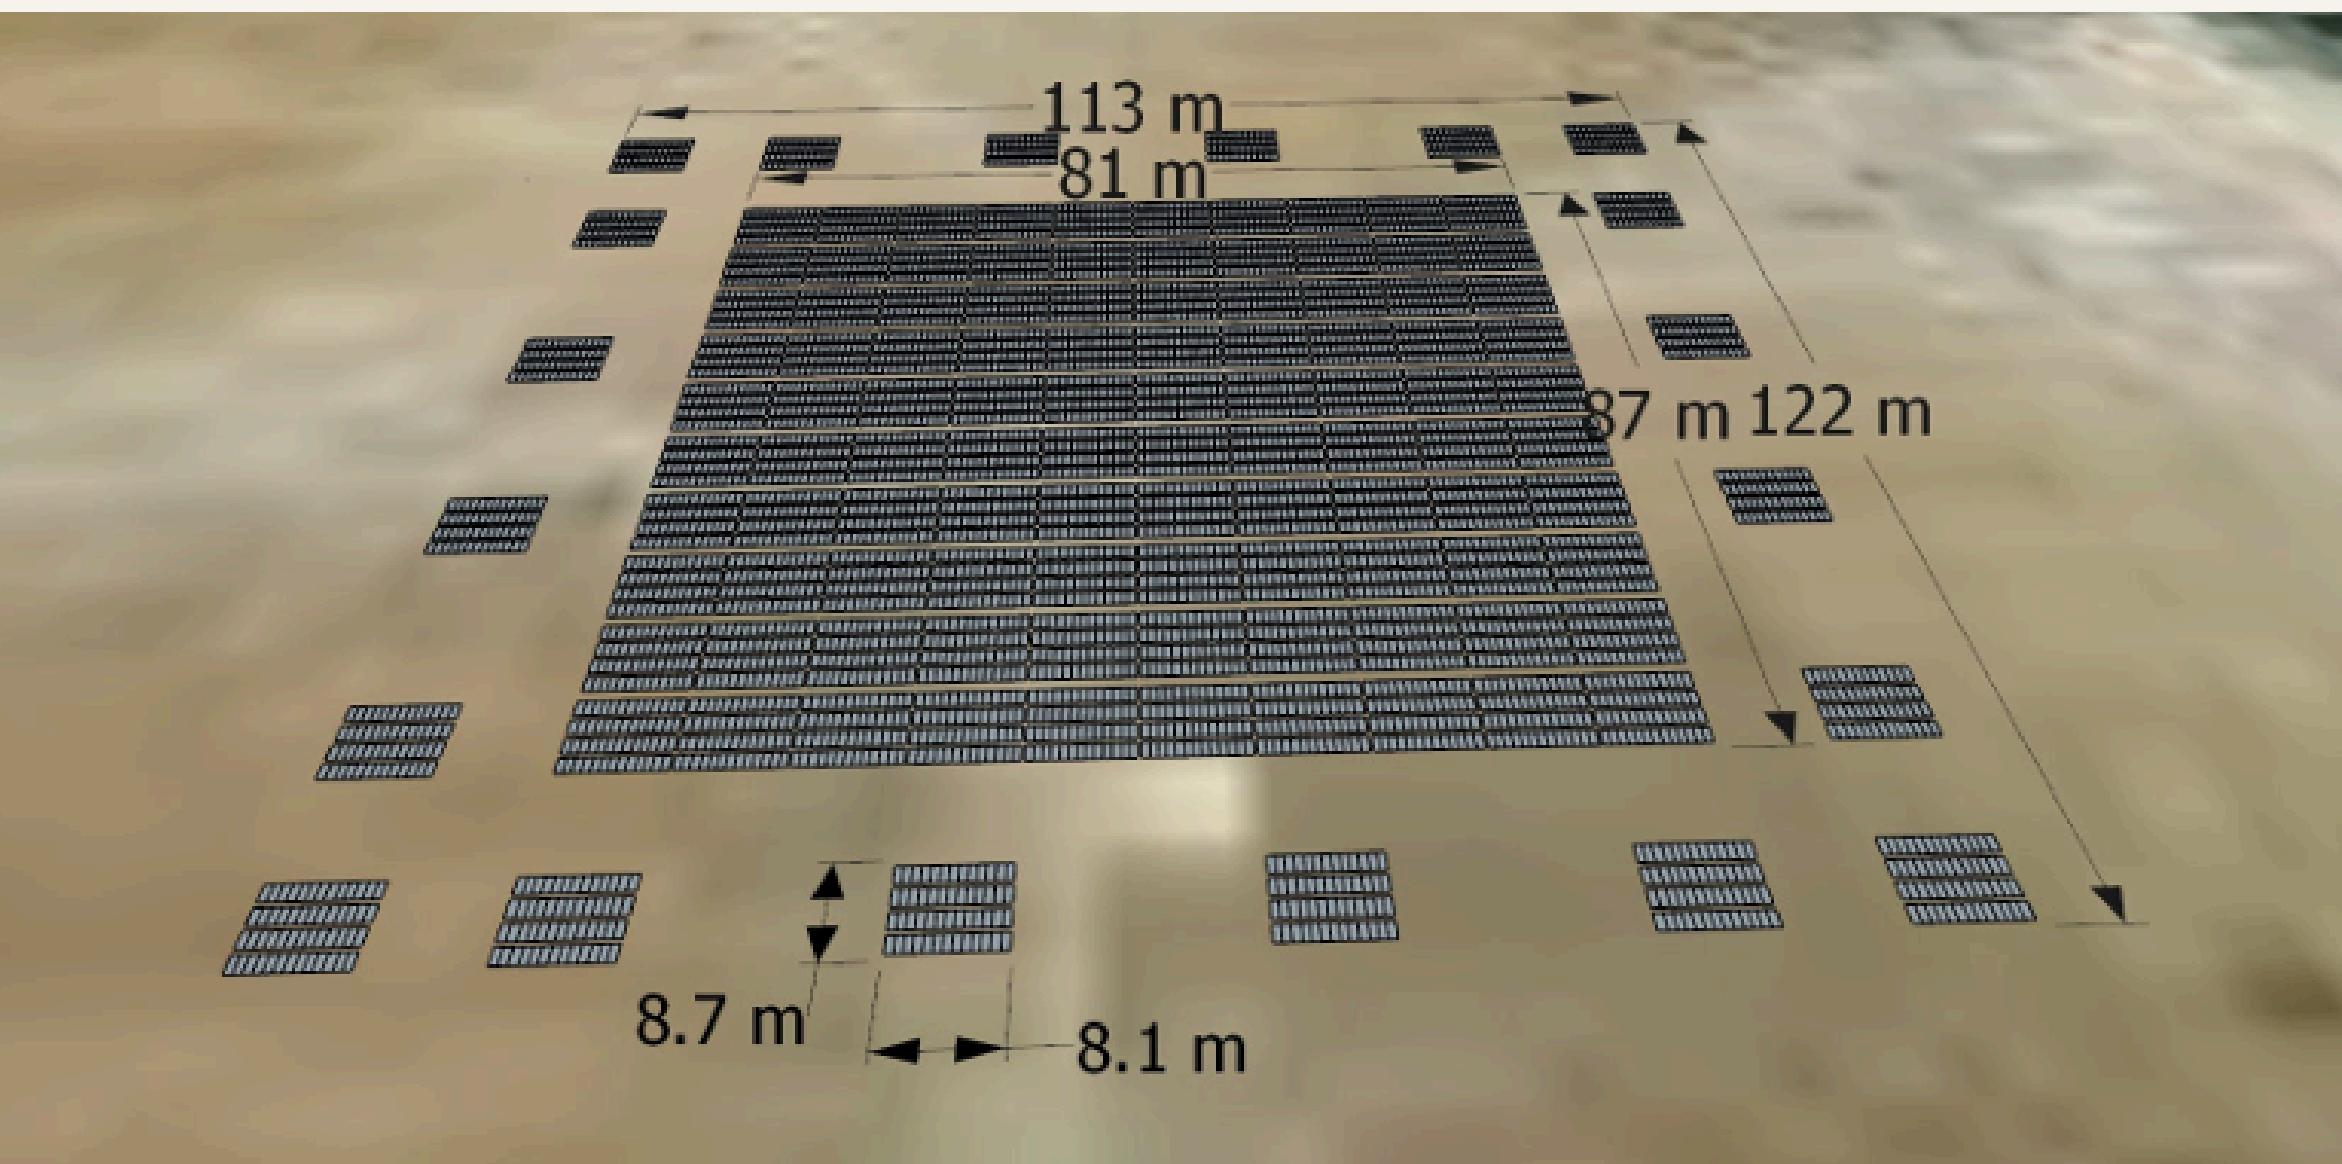


Figura 3. Esquema del arreglo de detectores de CONDOR.

¿Cómo funciona?

Los plásticos centelladores emiten una luz visible cuando son impactados por radiación (o sea, partículas cargadas) [3].

La señal de luz emitida viaja a través de fibras de desplazamiento de longitud de onda por el material para llegar a un fotomultiplicador de silicio, que lee la señal para convertirla en información [4].

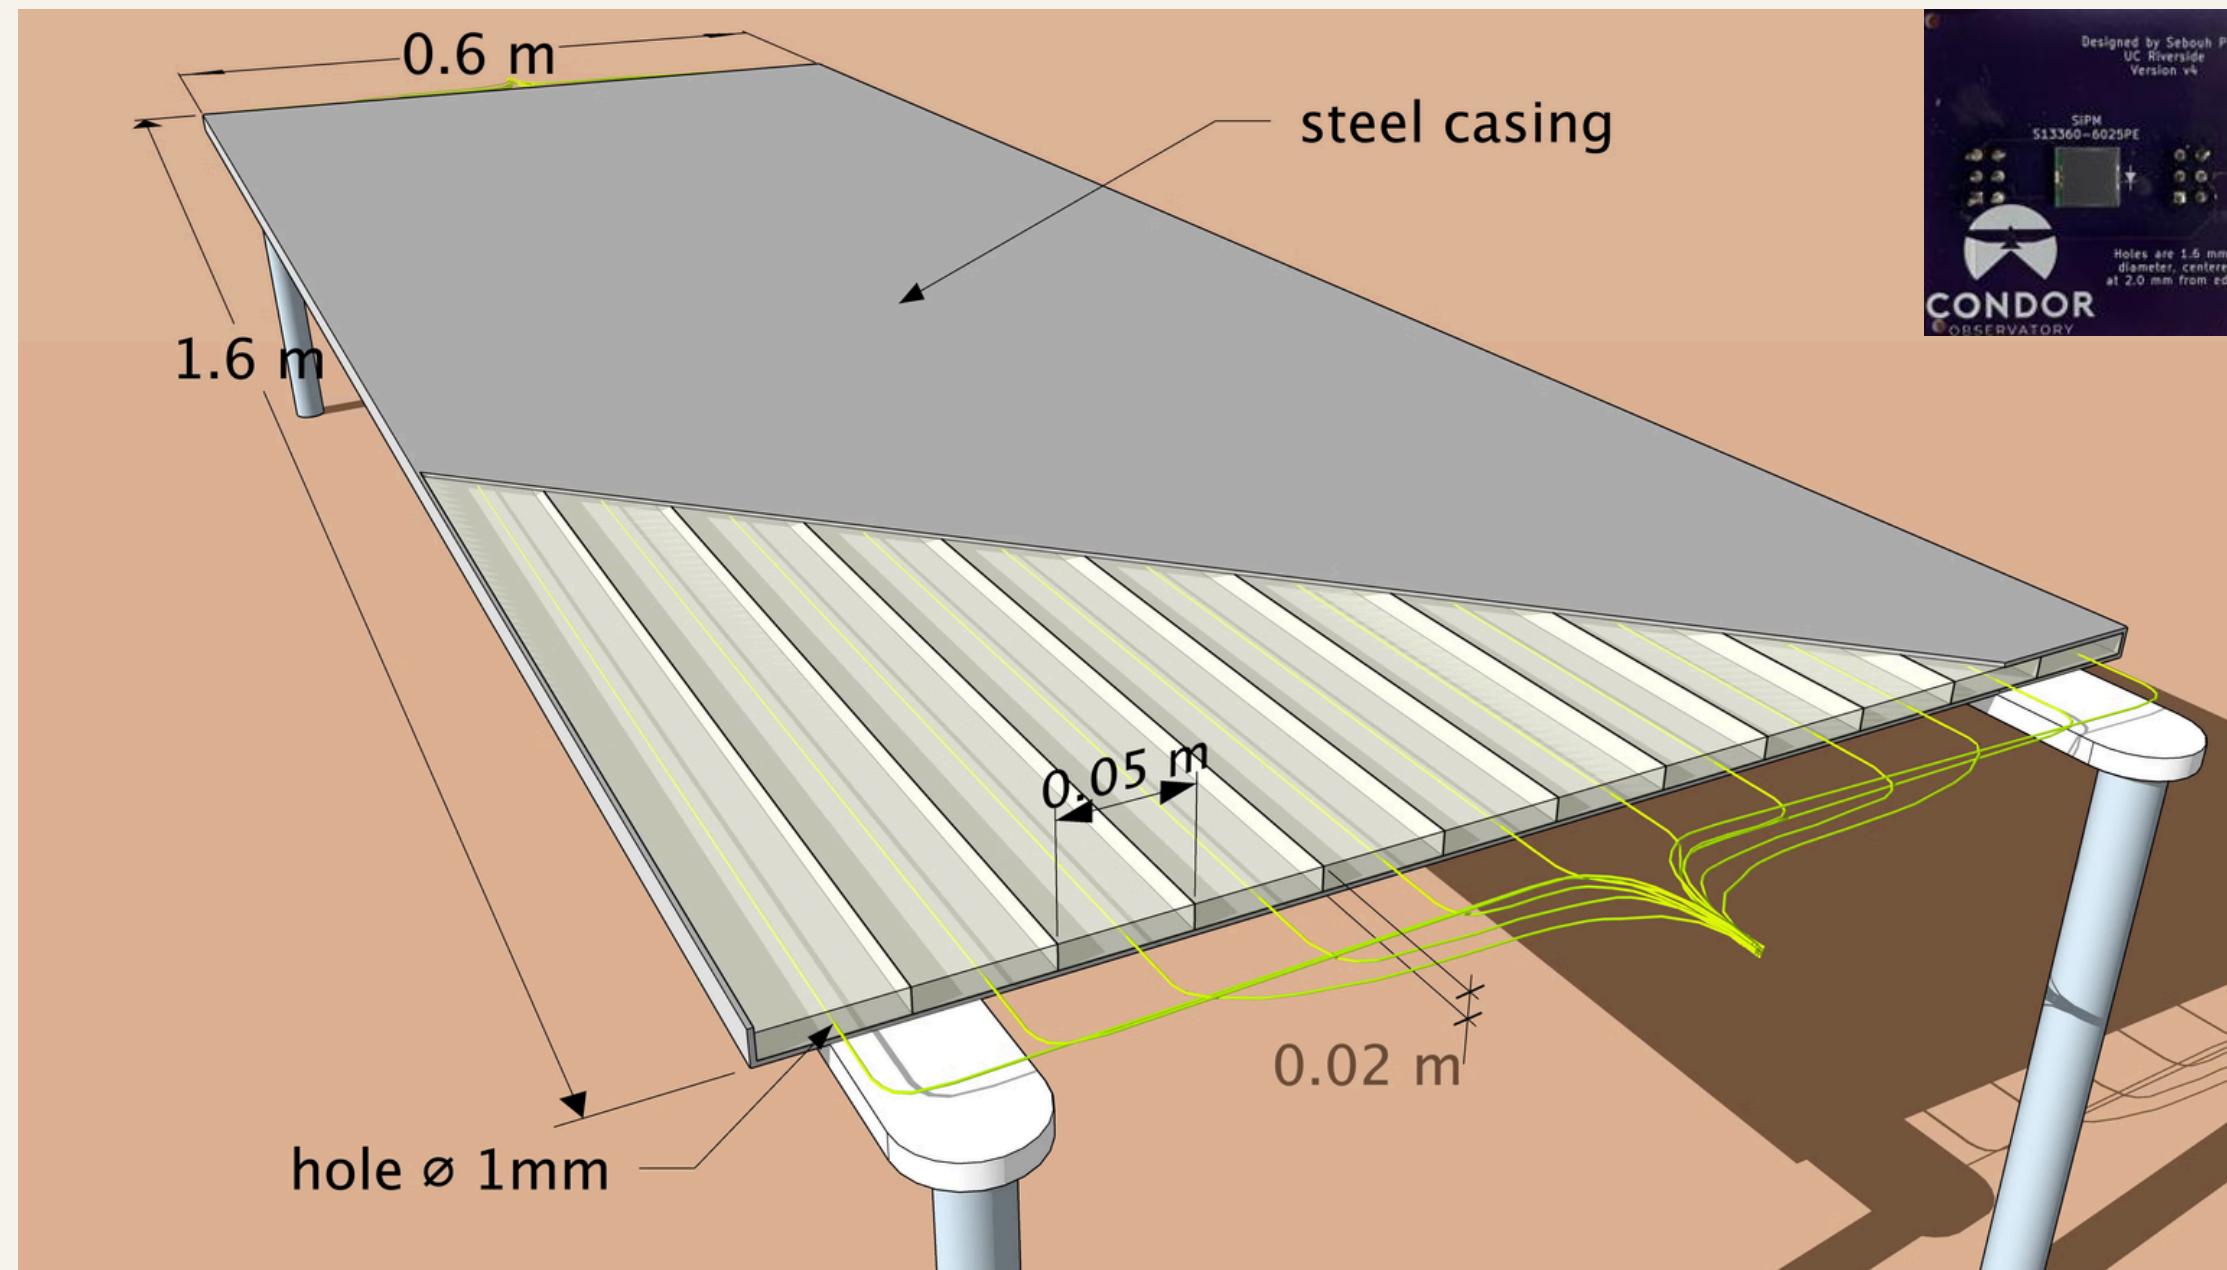


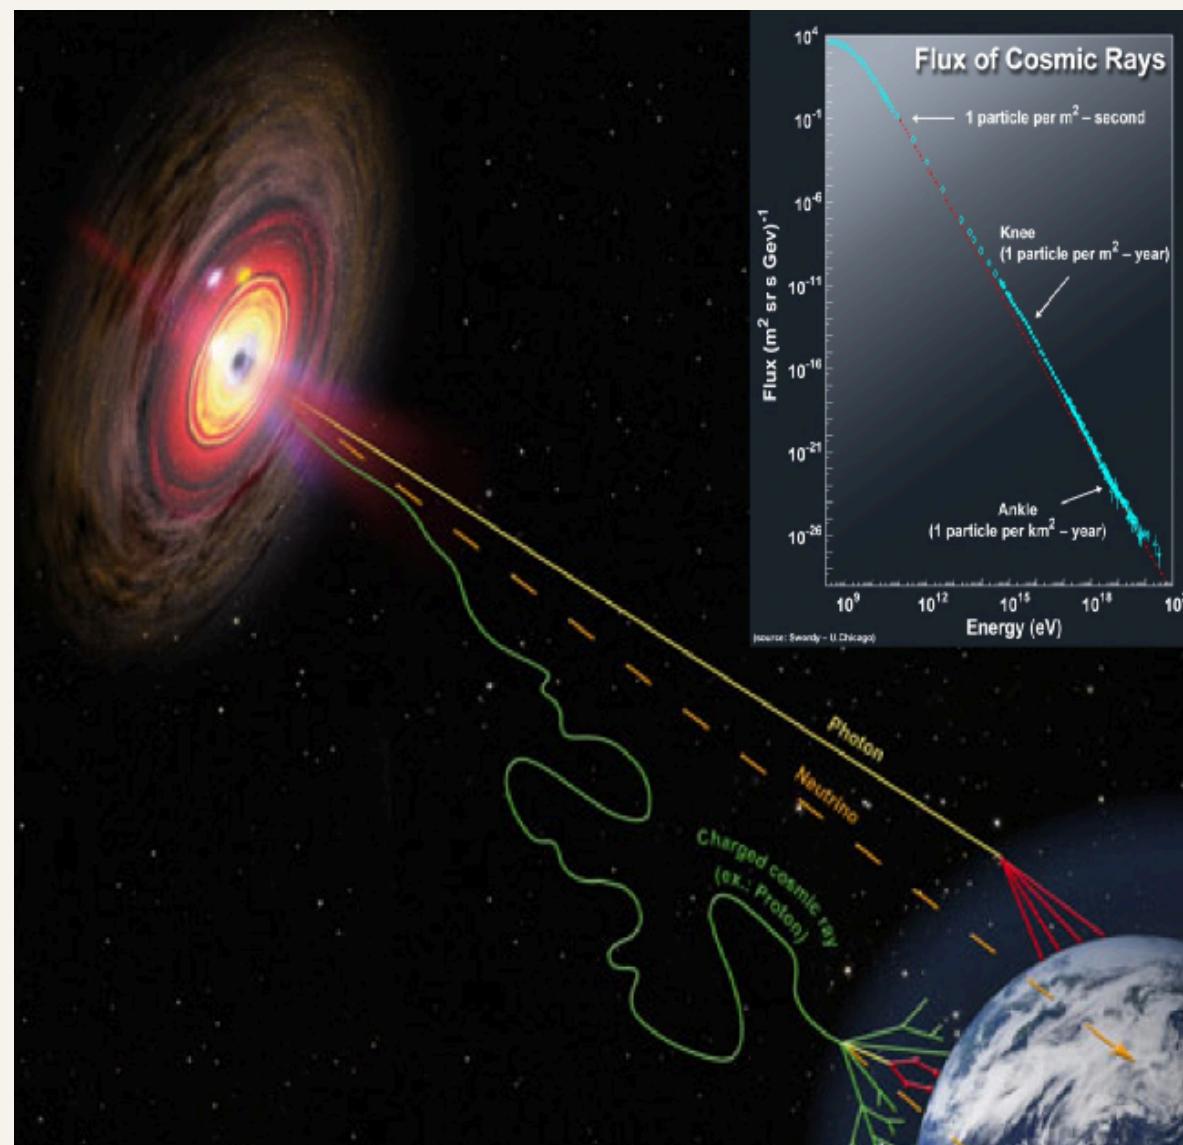
Figura 4. Esquema de un plástico centellador, la línea amarilla corresponde a la señal de luz emitida cuando le impacta radiación. A la esquina superior derecha un ejemplo de los fotomultiplicadores de silicio a utilizar en CONDOR.



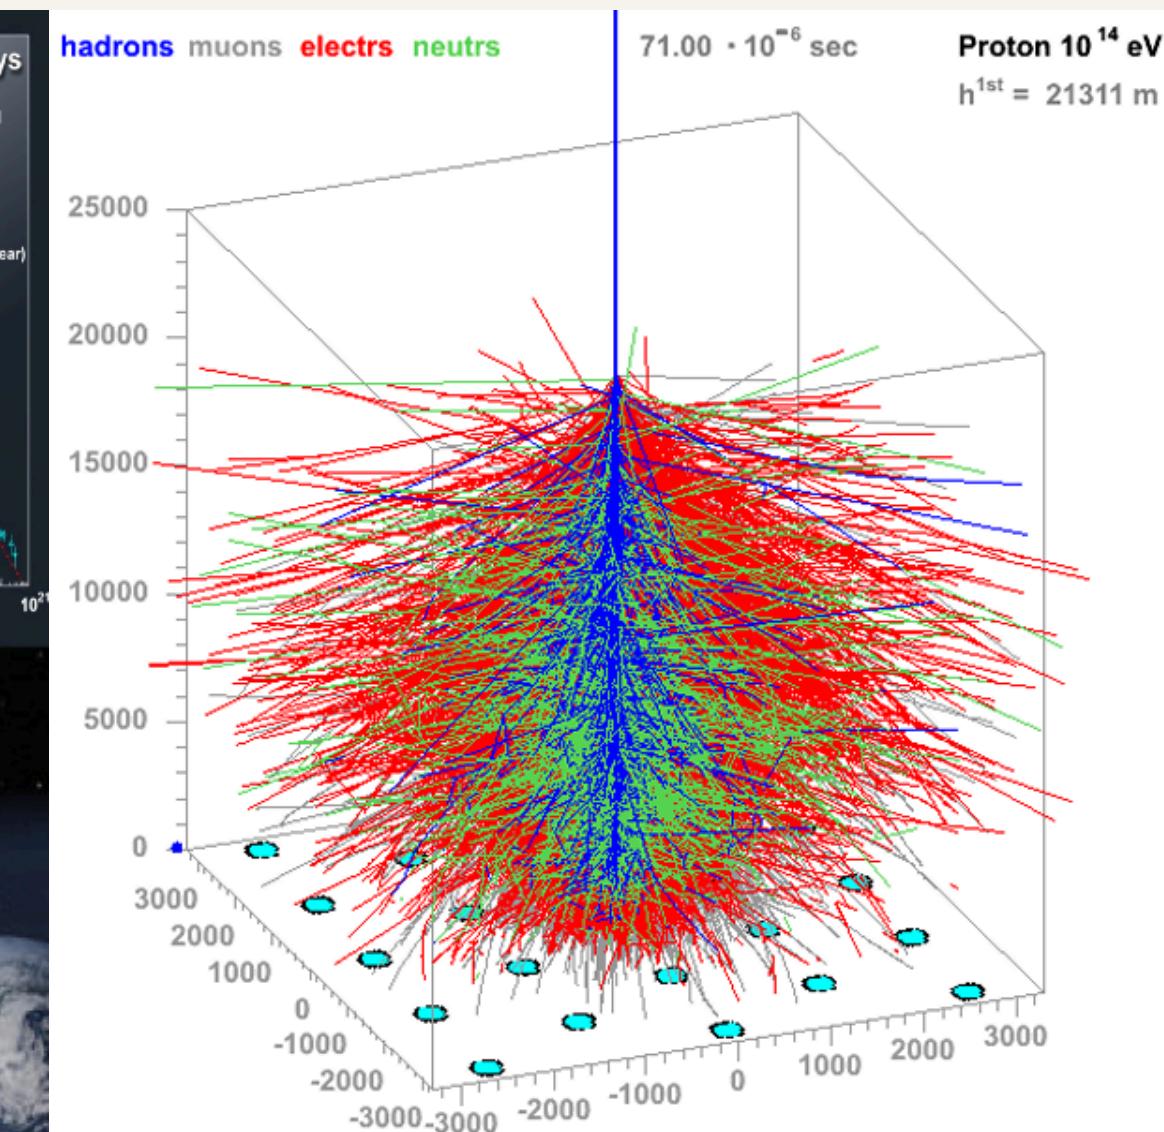
CORSIKA Software

CORSIKA es un programa capaz de generar simulaciones de EAS, aportando información detallada de las características fundamentales que las componen (dirección, tiempo, momentum, etc.) [5].

Estas simulaciones permitirán predecir o tener un preámbulo de qué pasará en CONDOR.



a)



b)

Figura 5. **a)** Representación del origen y comportamiento de distintos rayos cósmicos (fotón, protón y neutrinos). **b)** Simulación a detalle, usando CORSIKA, de una ducha de partículas generada por un protón primario con 10^{14} eV de energía incidente.

Simulaciones CONDOR

EJEMPLOS A 100 GEV

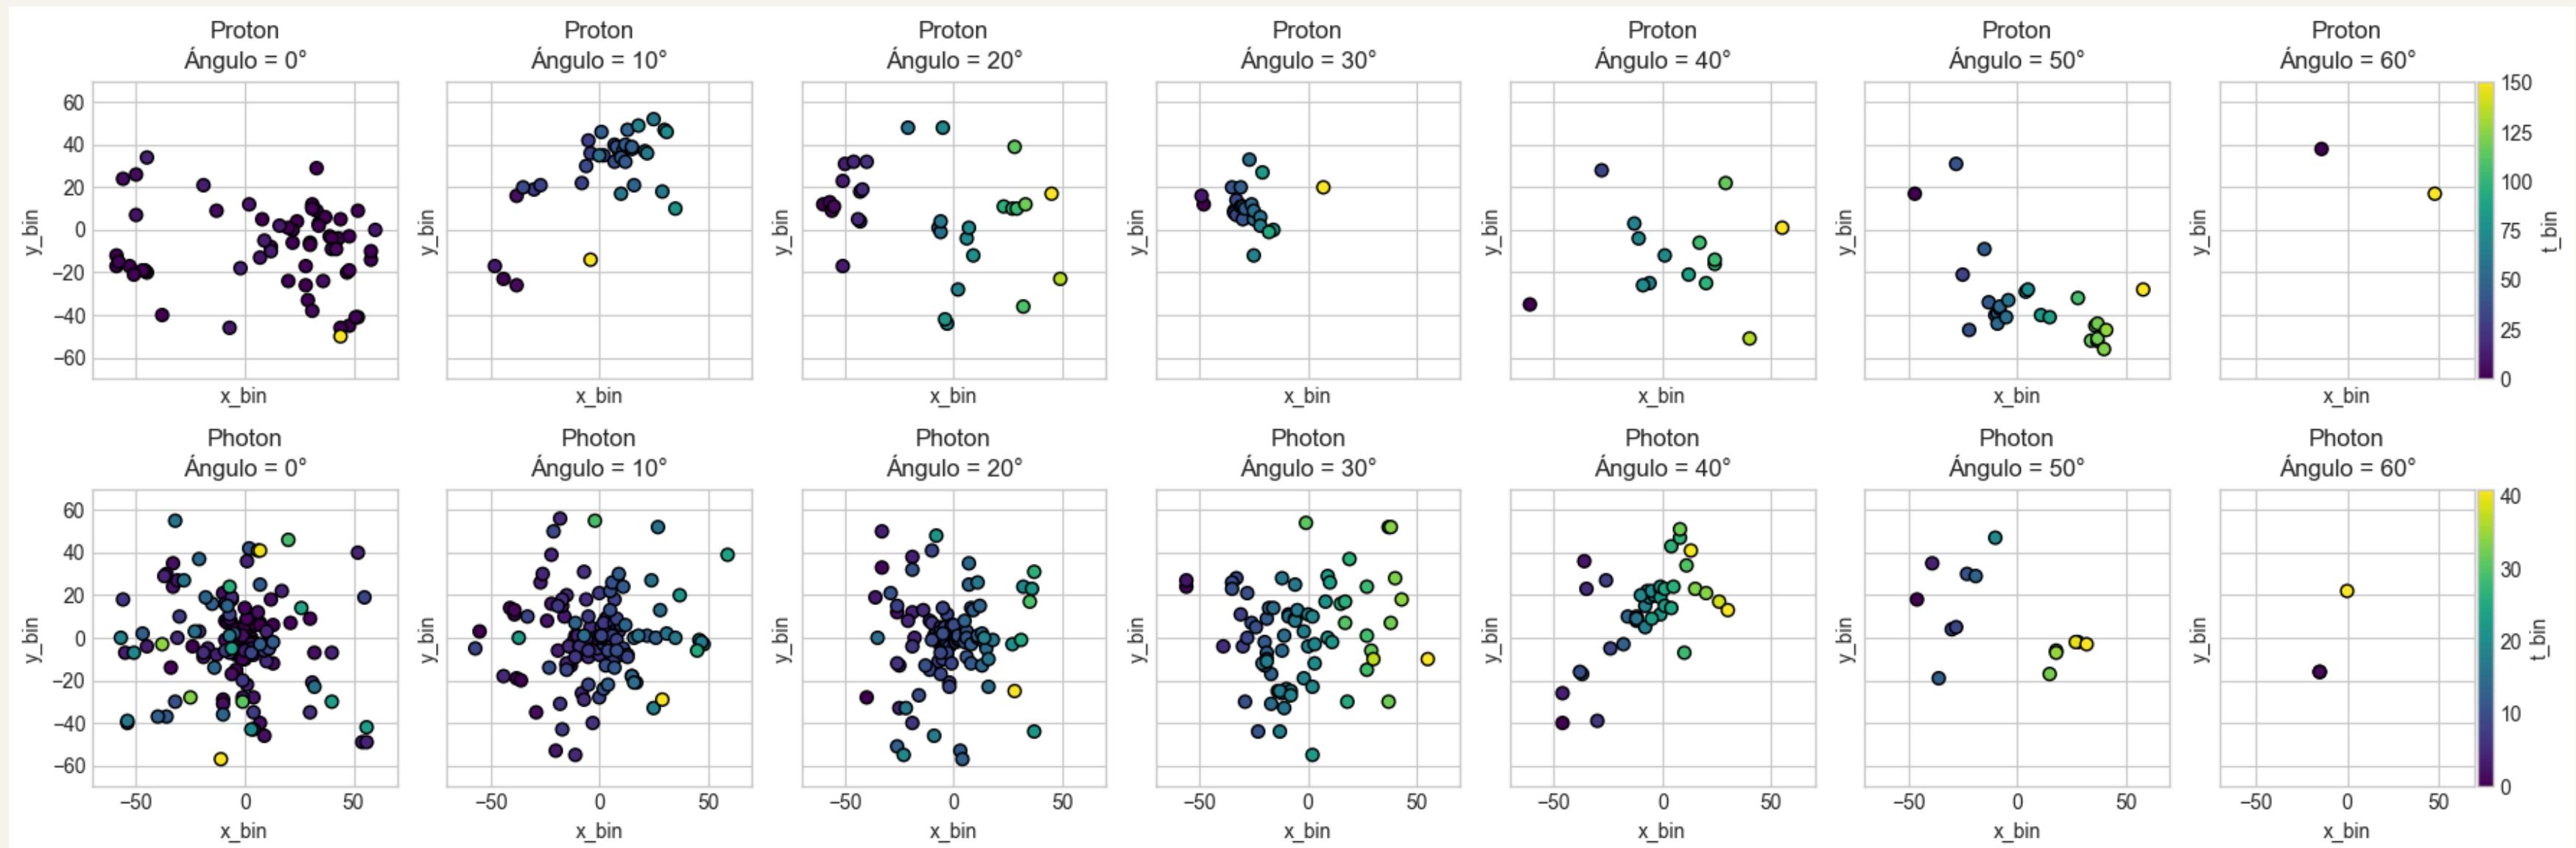


Figura 6. Simulaciones de EAS generadas por Protones (arriba) y Fotones (abajo) con 100 GeV de energía incidente bajo las condiciones de CONDOR (límite espacial correspondiente al área que cubrirá el arreglo de detectores, filtrado de partículas sin carga, mínimo de 2-3 partículas por simulación para evitar ruido). La barra de color corresponde a los tiempos de llegada de las partículas, mientras que los ejes corresponden a las coordenadas espaciales.

Simulaciones CONDOR

SESGOS DE DISTRIBUCIÓN EN BAJAS ENERGÍAS

Existe un claro **sesgo** en la distribución de los datos, esto debido a la gran diferencia de número de partículas que genera un fotón y un protón mediante sus interacciones [6]. Al ser pocas las partículas generadas, existe una menor chance a que impacten en el área de los detectores.

Asimismo, a medida que **aumenta** el **ángulo de incidencia**, las partículas secundarias generadas **disminuyen** debido a la alta dispersión que esto incumbe.

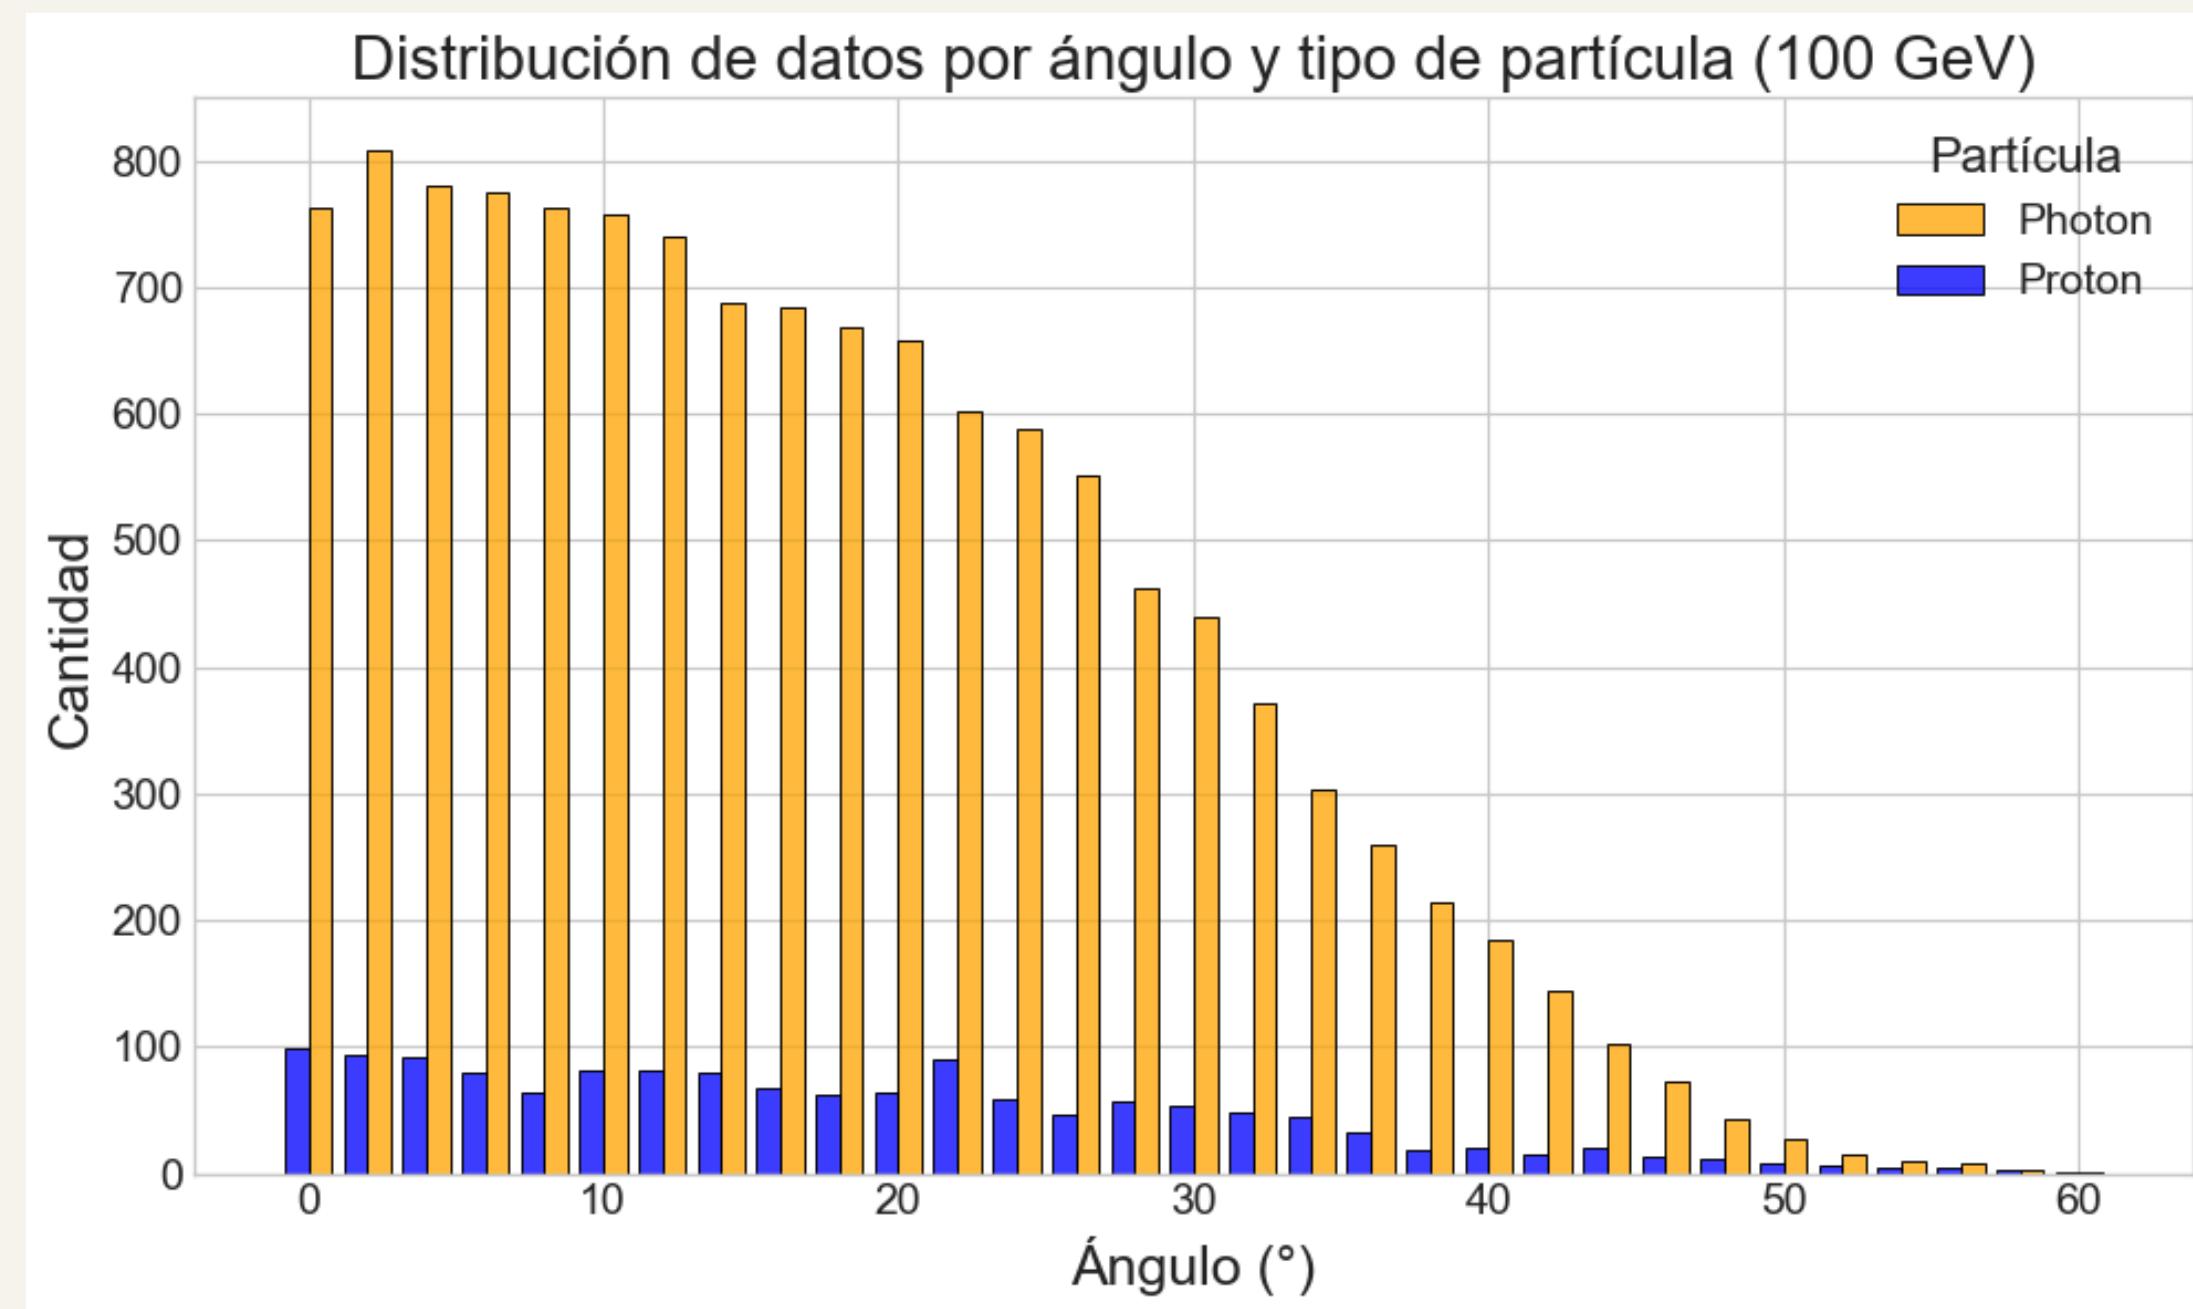


Figura 7. Distribución de los datos por ángulo y tipo de partícula (fotón en amarillo, protón en azul).

Simulaciones CONDOR

DISTRIBUCIÓN DE DATOS EN ALTAS ENERGÍAS

A medida que **aumenta** la energía, esto produce más partículas, lo que se traduce en **más datos**, solucionando así el problema del sesgo en las distribuciones.

Sin embargo, para energías pequeñas esto sigue ocurriendo, por lo que será necesario hacer un **balanceo** de datos a partir de las simulaciones.

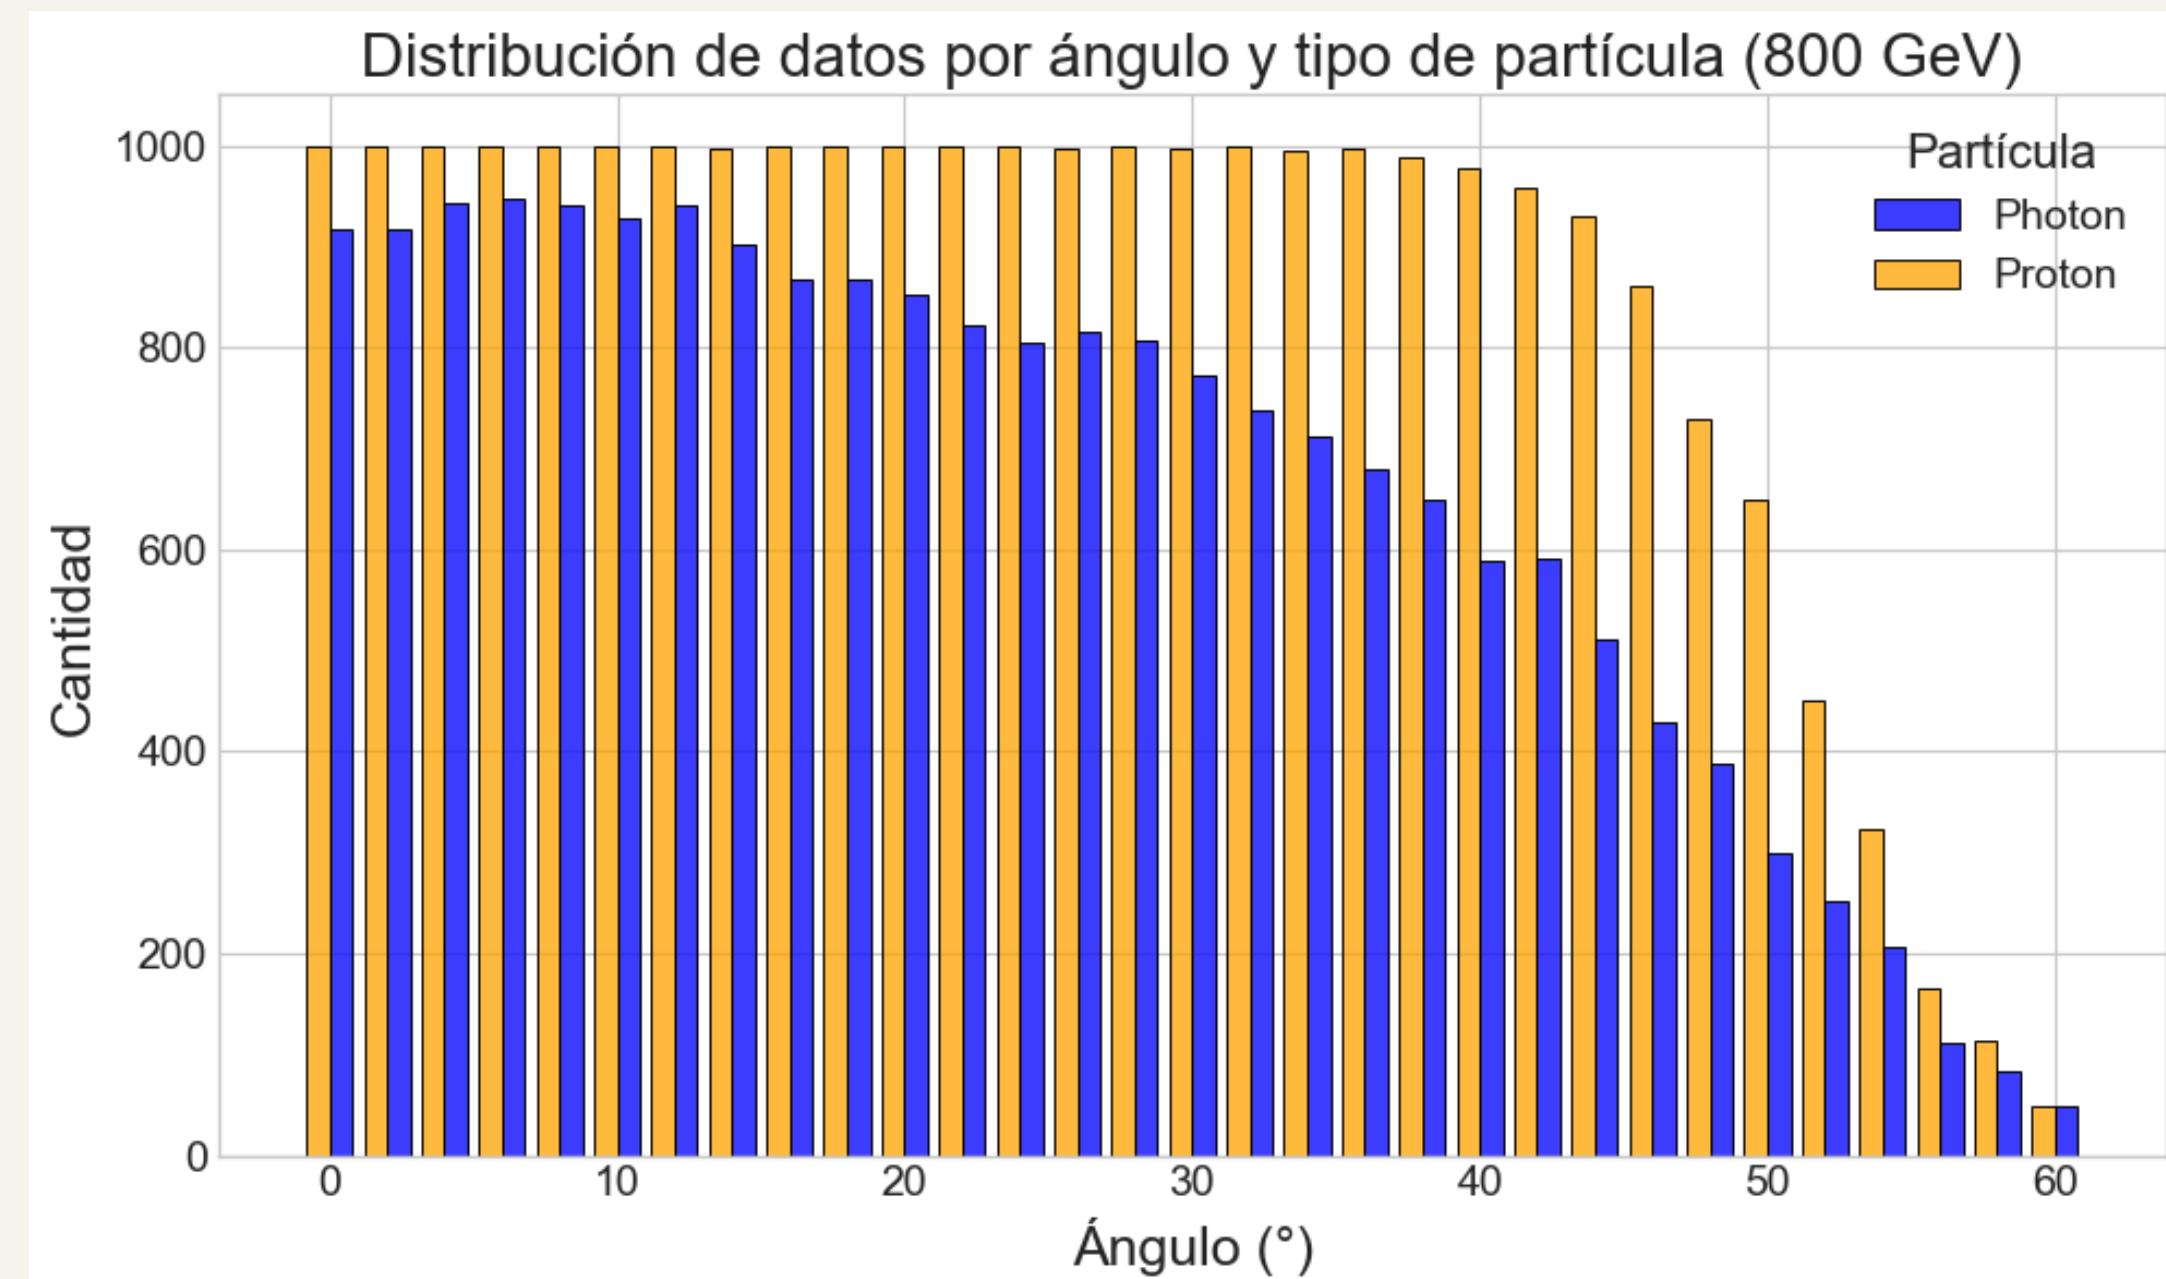


Figura 8. Distribución de los datos por ángulo y tipo de partícula (fotón en naranjo, protón en azul).

Simulaciones CONDOR

BALANCEO DE DATOS

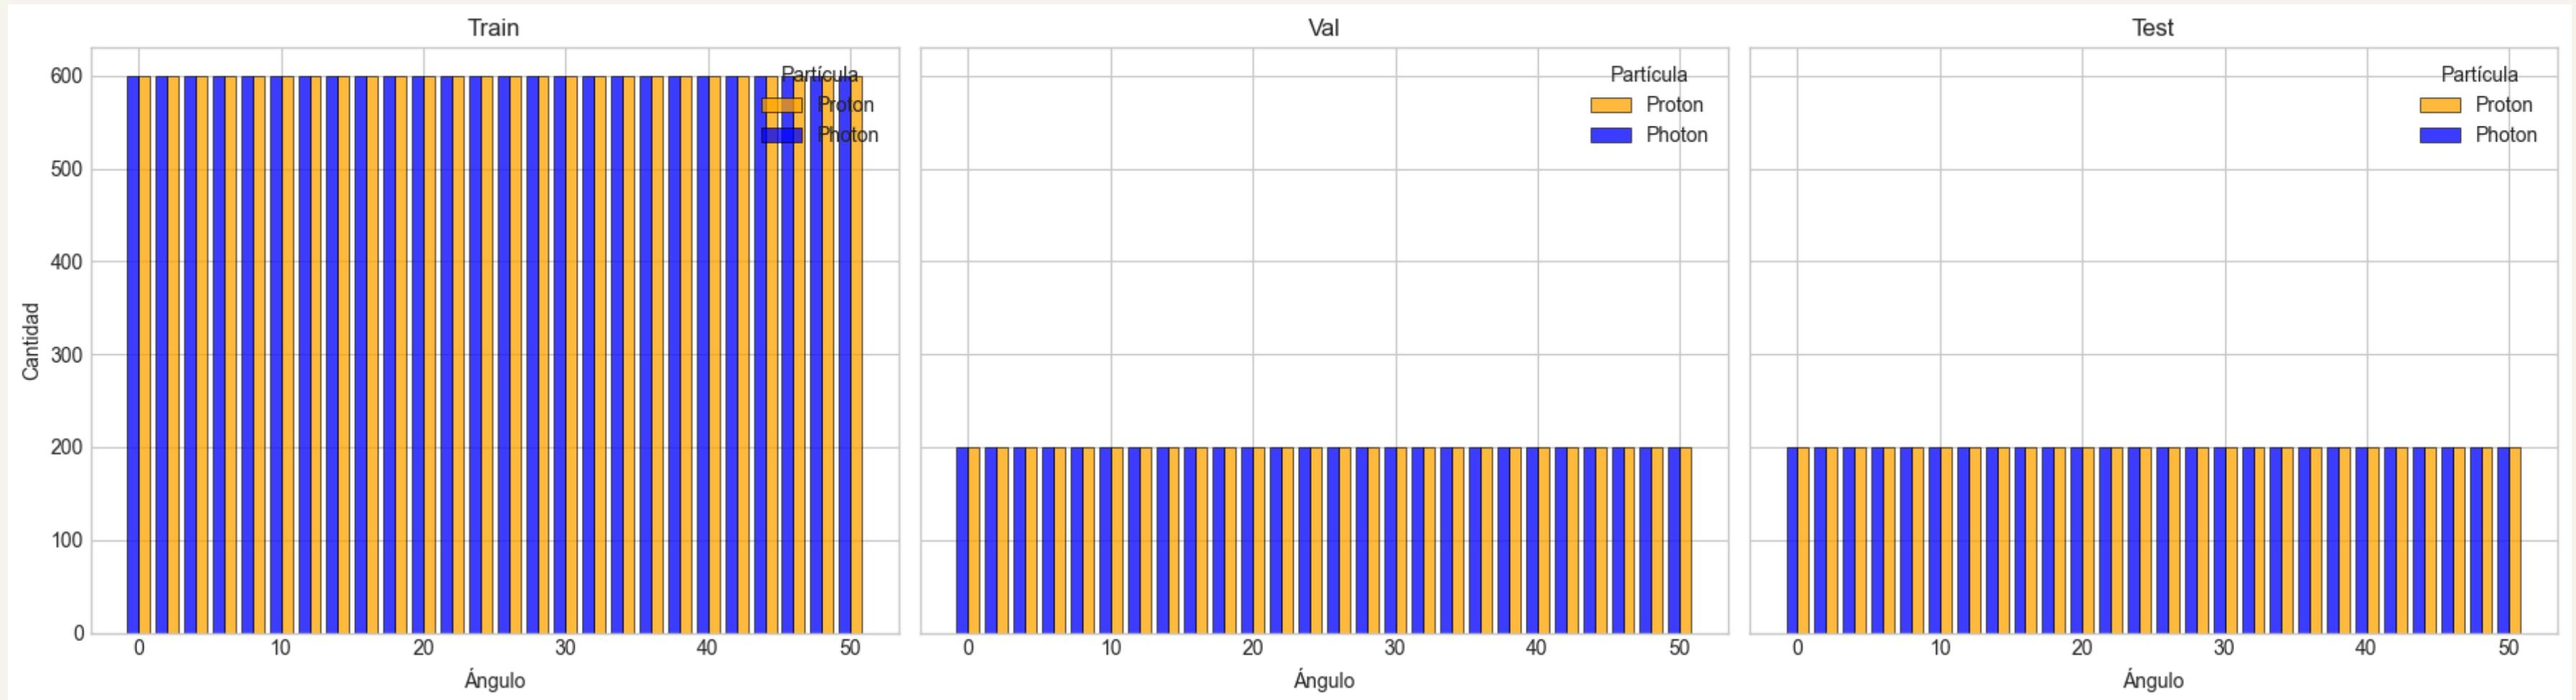


Figura 9. Distribución de los datos por ángulo y tipo de partícula en los conjuntos de entrenamiento, validación y prueba (fotón en naranjo, protón en azul). Lo ideal es una distribución de 1000 datos por ángulo, y la división corresponde a 60% entrenamiento, 20% validación y 20% prueba. Este balanceo de datos es necesario para que el posterior modelo de red neuronal no prediga únicamente una sola partícula.

Simulaciones CONDOR

REPRESENTATIVIDAD DE LOS DATOS BALANCEADOS - 100 GEV

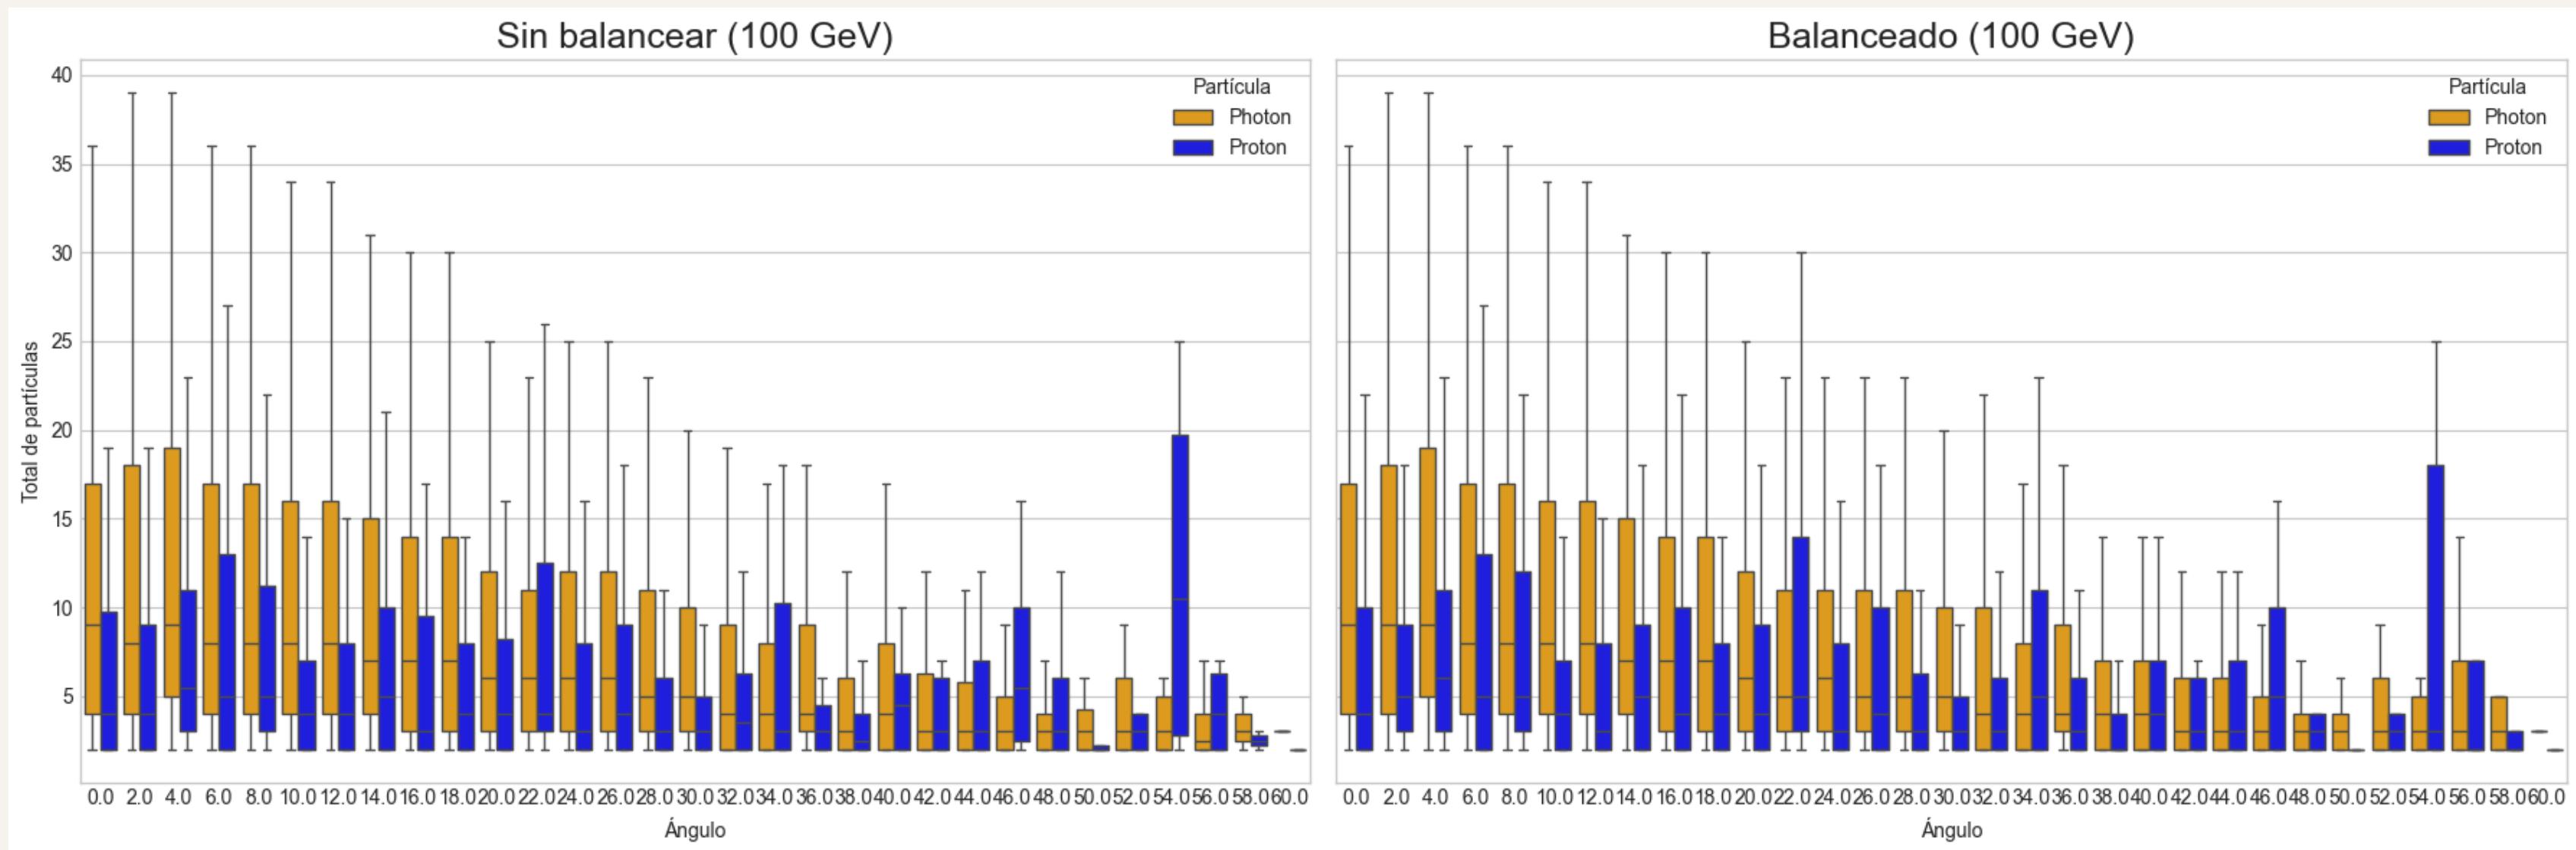


Figura 10. Distribución tipo boxplot del **conteo total de partículas secundarias** por ángulo y por tipo de partícula (fotón naranjo, protón azul). Al ser distribuciones similares, tanto la sin balancear como balanceada, podemos decir que no se pierde representatividad al hacer el aumento de datos. Por otra parte, existe un claro patrón en el comportamiento general, pero en ángulos grandes ($> 50^\circ$).

Simulaciones CONDOR

REPRESENTATIVIDAD DE LOS DATOS BALANCEADOS - 100 GEV

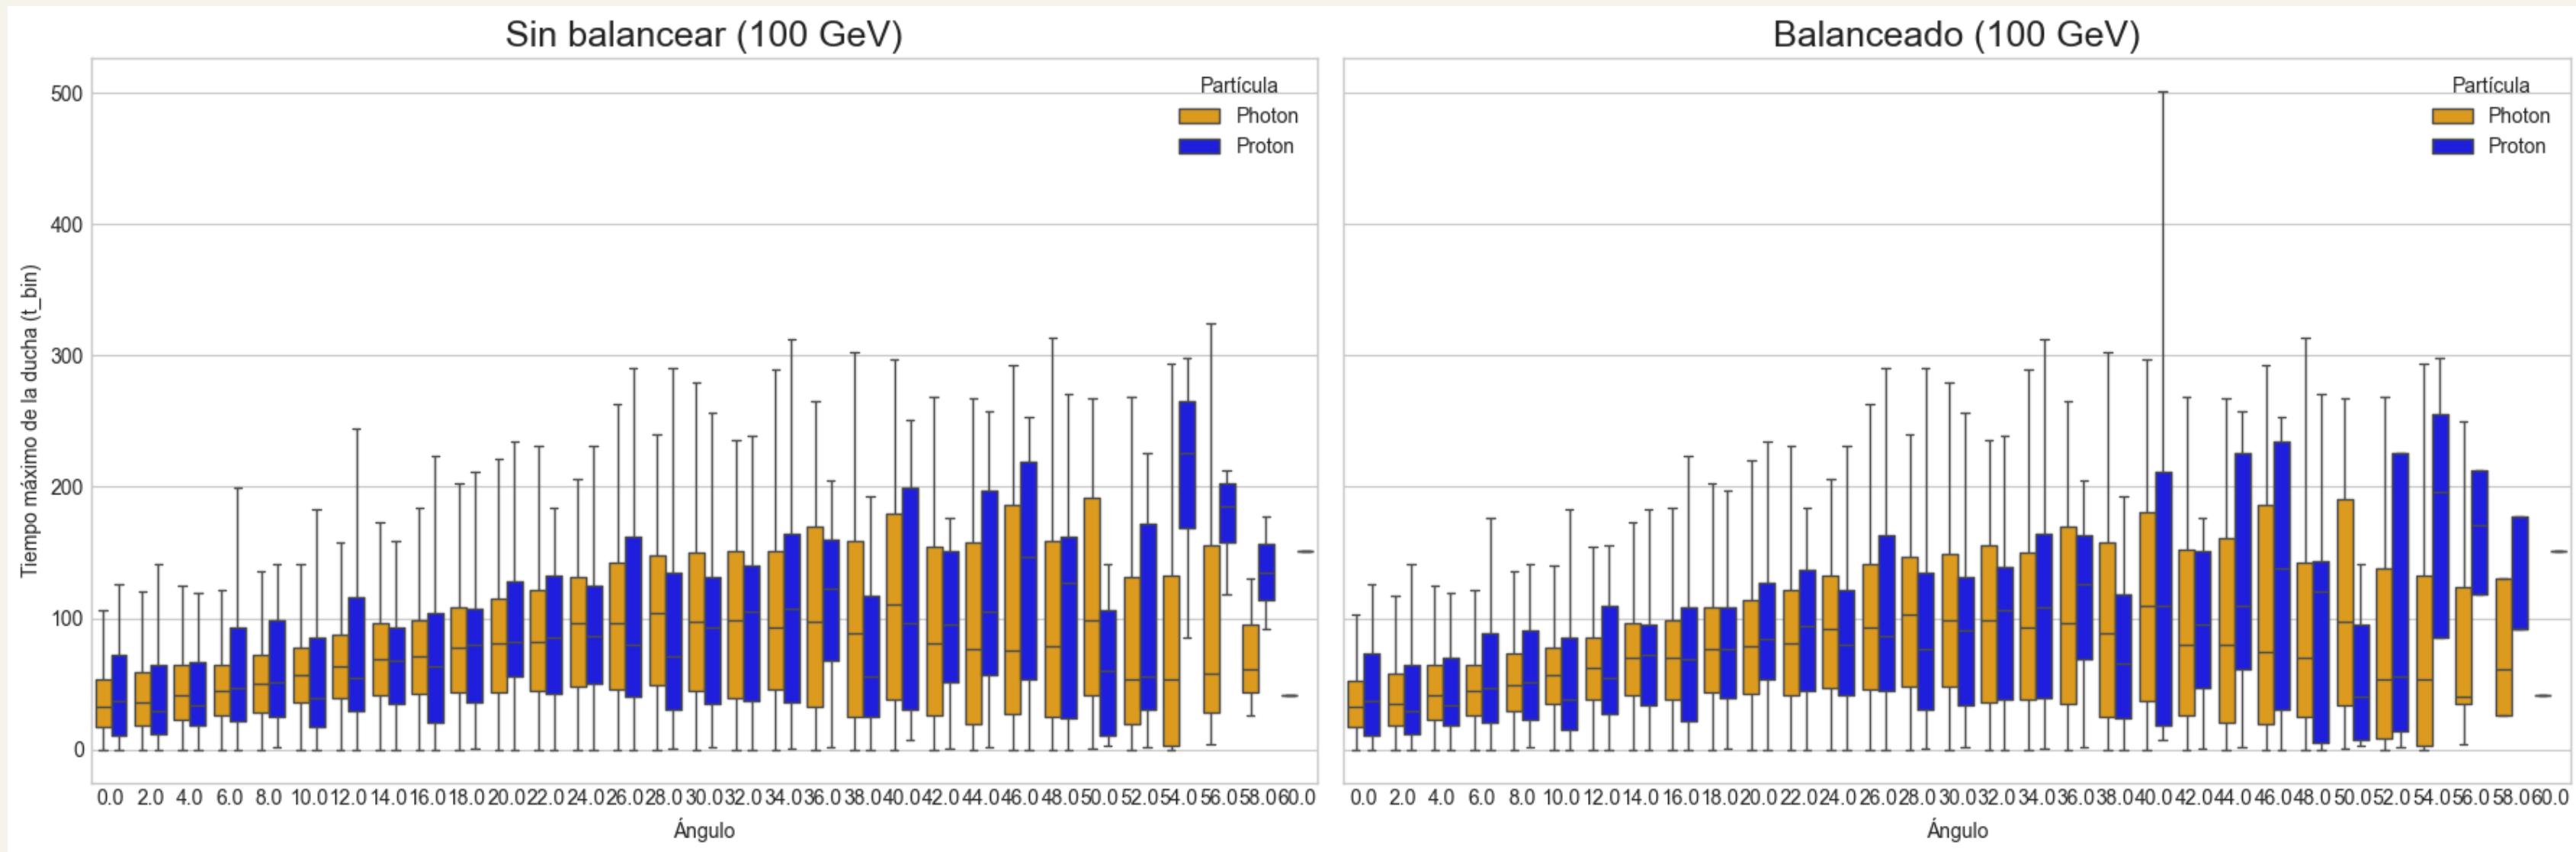


Figura 11. Distribución tipo boxplot de la **duración máxima** de las EAS por ángulo y por tipo de partícula (fotón naranjo, protón azul). Sigue sucediendo lo mismo que con el conteo total de partículas; no se pierde representatividad. Sin embargo, existe un cierto patrón, pero sólo hasta ángulos grandes ($> 50^\circ$).

Simulaciones CONDOR

REPRESENTATIVIDAD DE LOS DATOS BALANCEADOS - 800 GEV

Como en energías más altas se logra mantener la representatividad y un patrón certero en los datos, podemos generar predicciones más precisas al manejar correctamente el problema de la distribución.

Entonces, si podemos generar buenos resultados en estas energías, podemos suponer que en energías más bajas sólo necesitamos más datos para cubrir el sesgo y así tener la misma calidad de predicción.

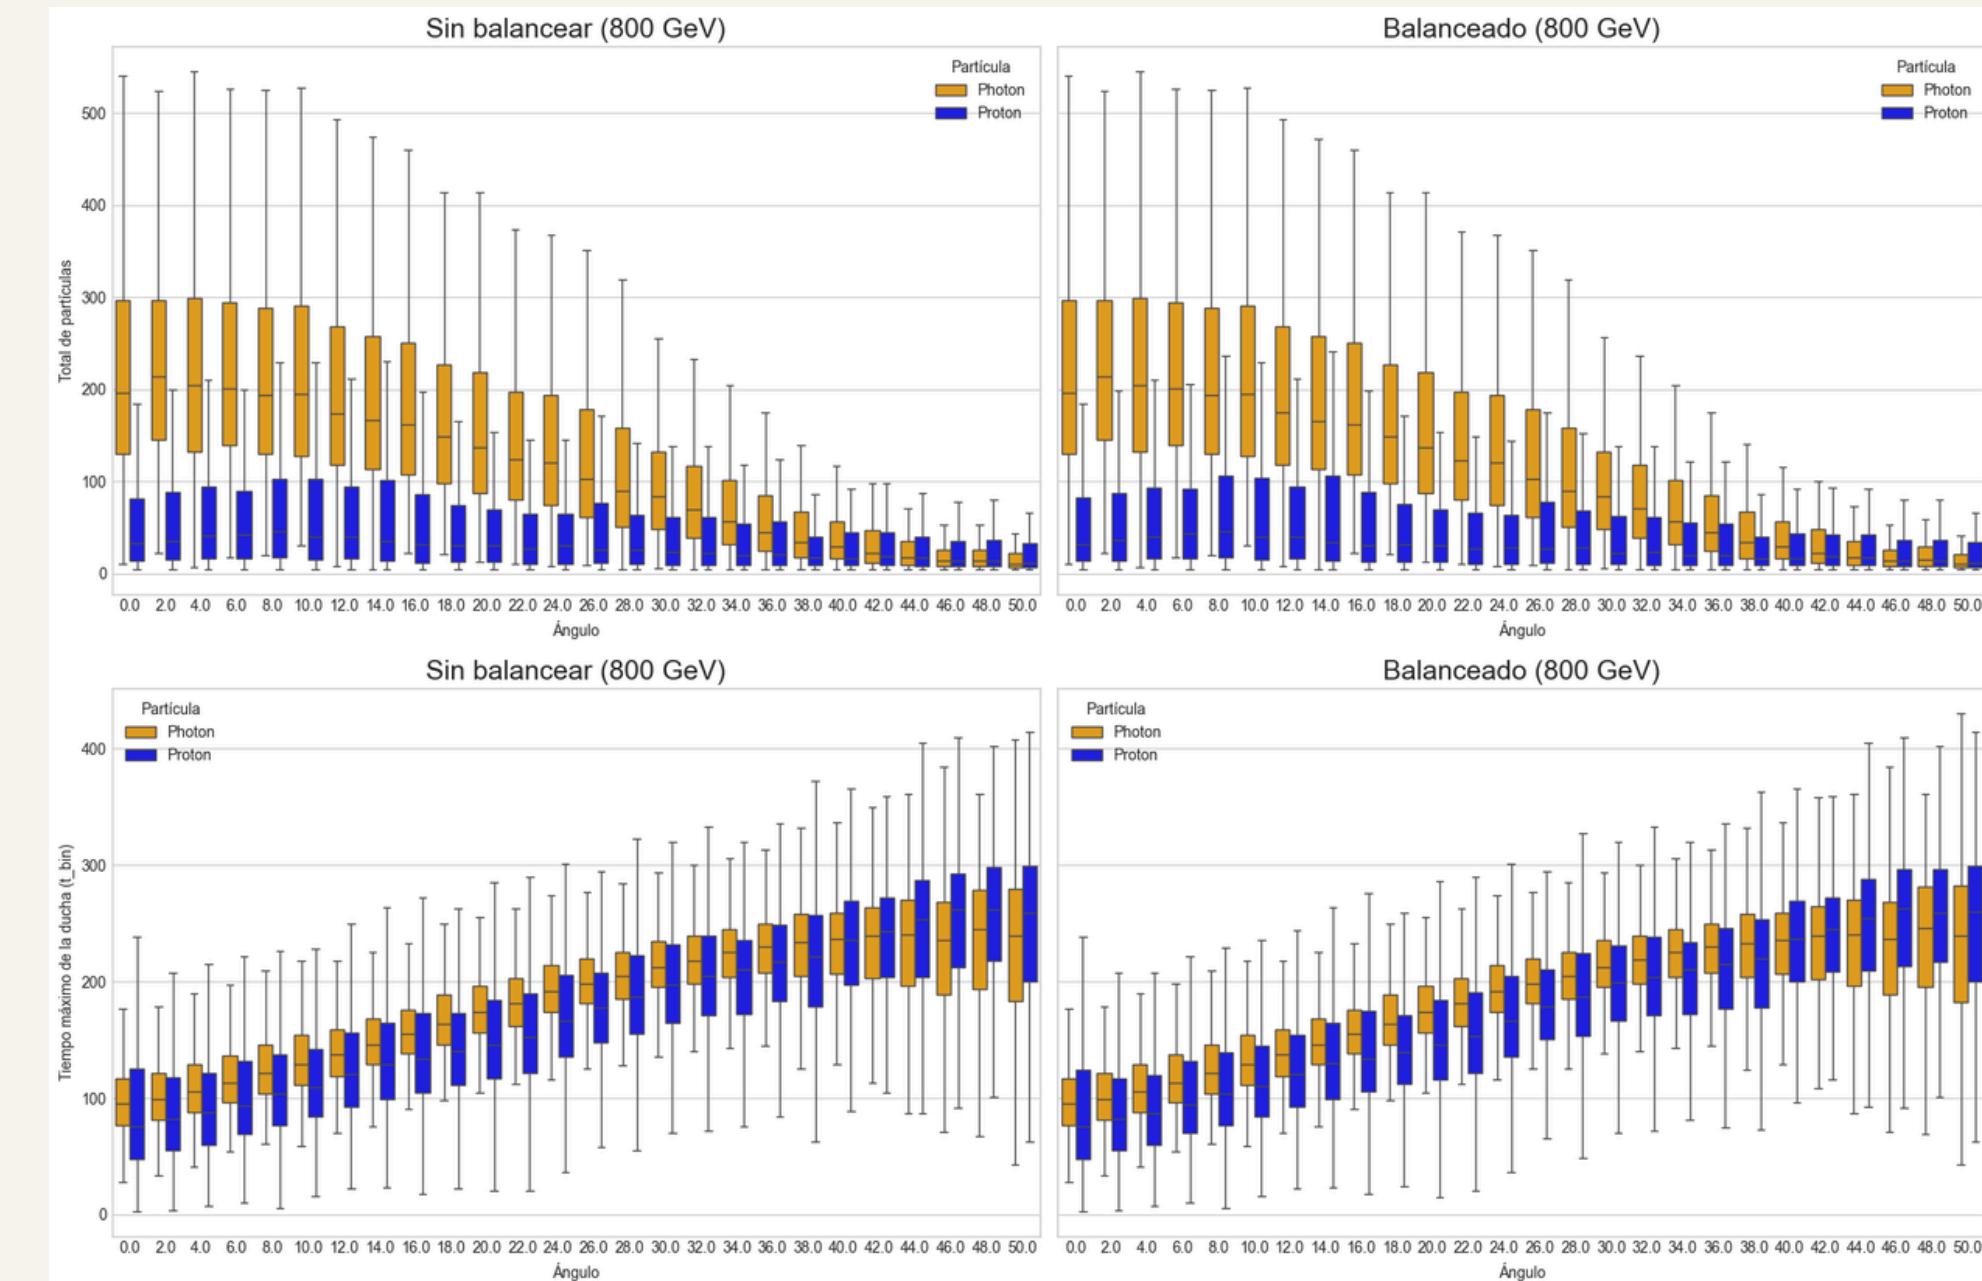


Figura 12. Distribución de conteo de partículas (arriba) y de duración máxima (abajo) para EAS de 800 GeV de energía incidente.

Arquitectura del modelo

TRANSFORMERS + CONVOLUCIONALES 1D

El modelo presentado en la primera entrega del proyecto consistía en una red LSTM + CONV1D, que funcionaba bastante bien, pero las secuencias no eran muy representativas de las EAS (por el timestep fijo que se le definía a cada secuencia).

Ahora, las secuencias pasan a ser mucho más complejas (por tener su propia longitud y mantener sus características “intactas”). Esto nos obliga a optar por una arquitectura más compleja, reemplazando las capas LSTM por un Transformer.

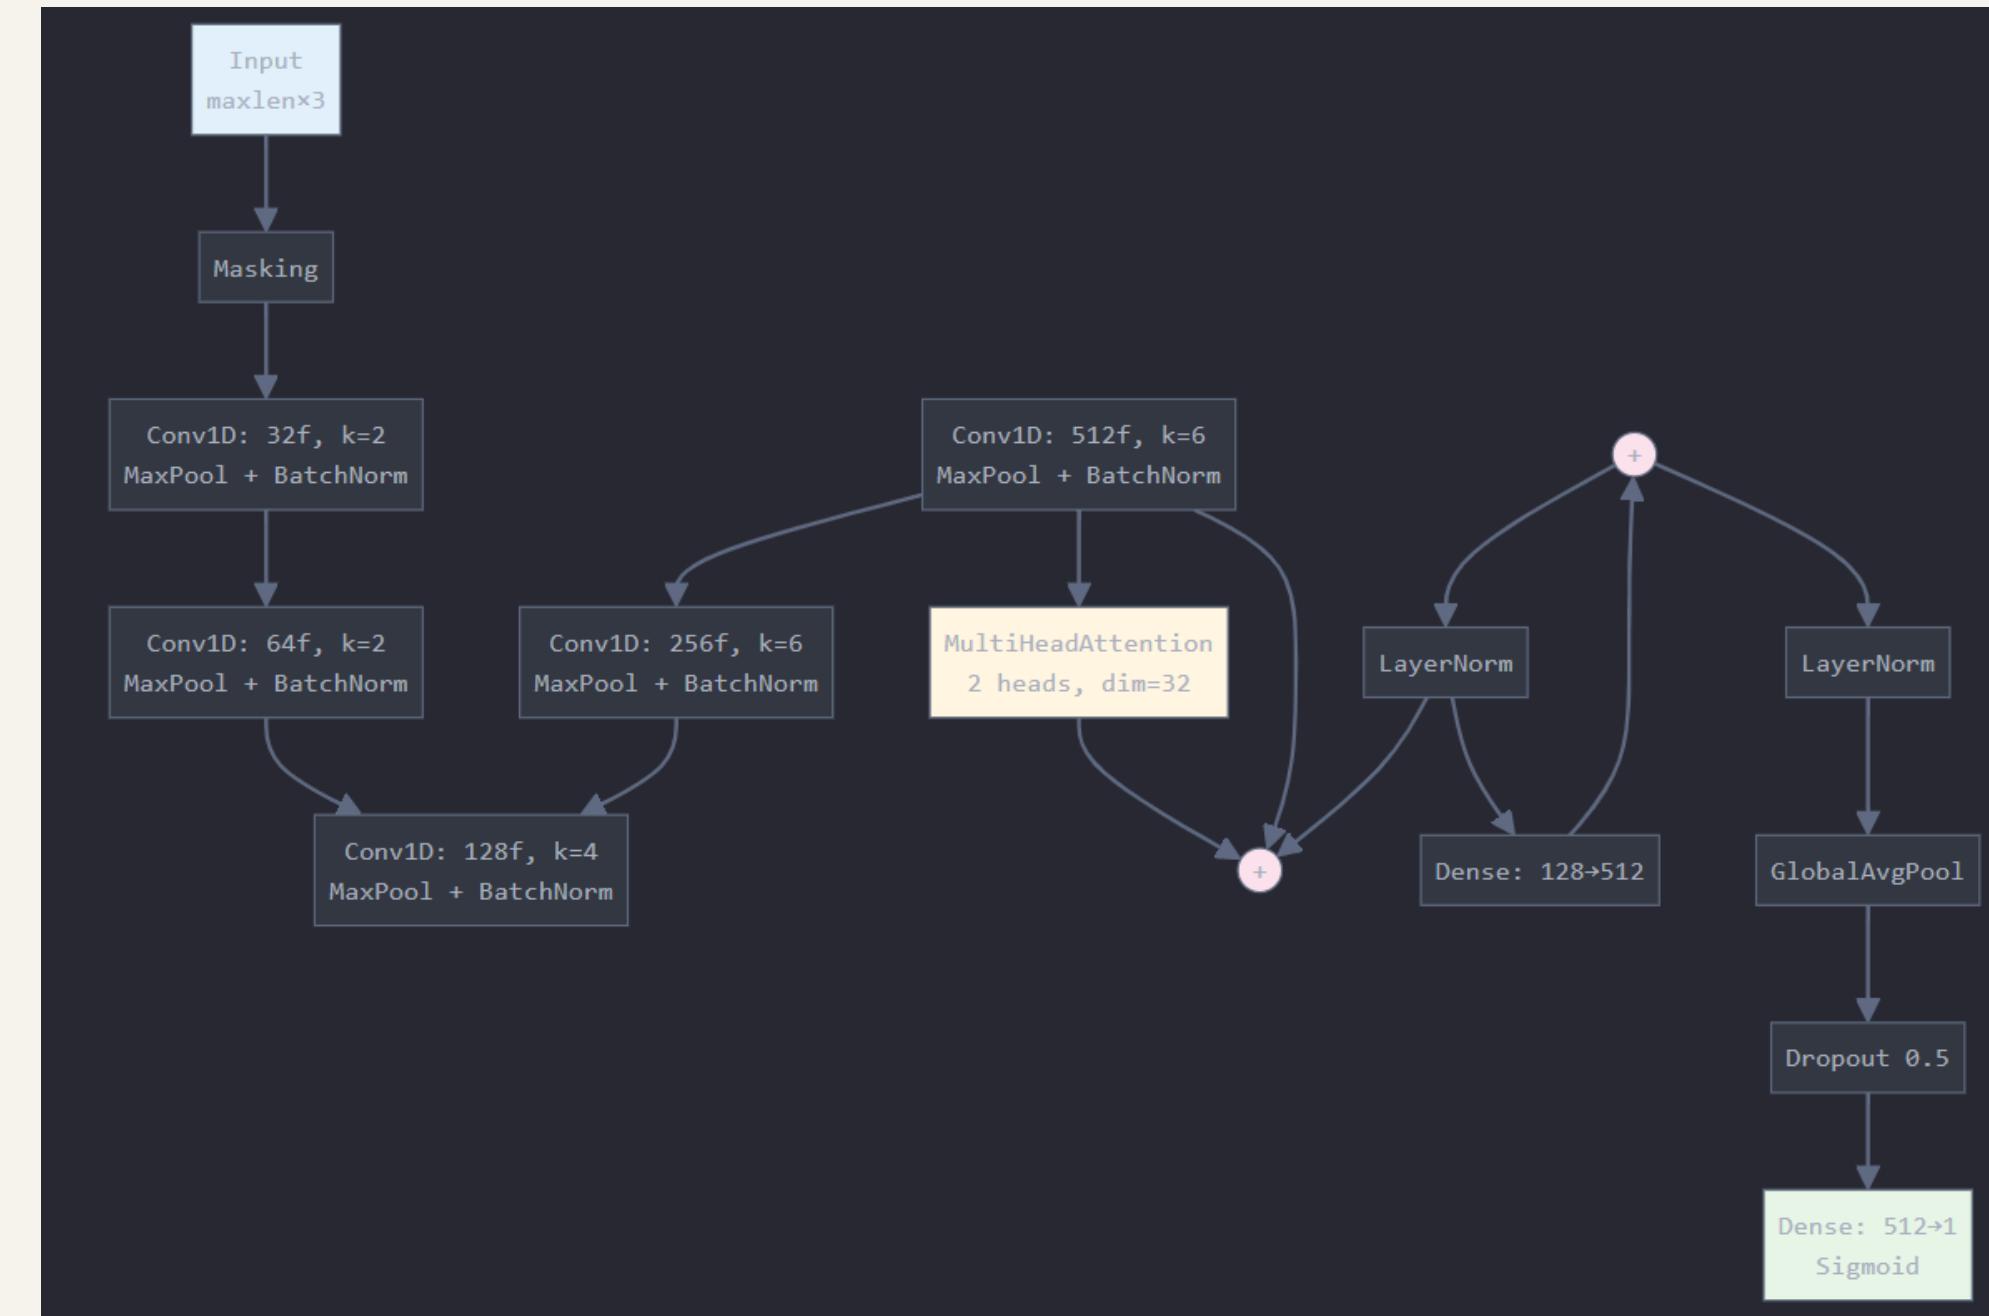


Figura 13. Arquitectura de la red neuronal utilizada para la clasificación de rayos cósmicos (diagrama hecho con Claude Sonnet 4).



Arquitectura del modelo

TRANSFORMERS + CONVOLUCIONALES 1D

Entrada. Secuencias de longitud variable ($\text{maxlen} \times 3$ características; espacio-temporalidad)

- **Preprocesamiento:** Capa de enmascaramiento para manejar secuencias de diferentes longitudes.

Extracción de características:

- 5 bloques **CONV 1D** progresivos: Incremento gradual de filtros ($32 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512$).
Kernels variables (2, 2, 4, 6, 6). MaxPooling y BatchNormalization en cada bloque.

Mecanismo de atención

- **MultiHeadAttention** con conexiones residuales (para clasificación 2 cabezales, para regresión 4).
- **Transformer block:** Con feedforward network y normalización por capas

Clasificación final: GlobalAveragePooling, Dropout y capas densas para salida binaria.

Estado del Arte

RECONSTRUCCIÓN DE ÁNGULO, ENERGÍA Y PROFUNDIDAD ATMOSFÉRICA

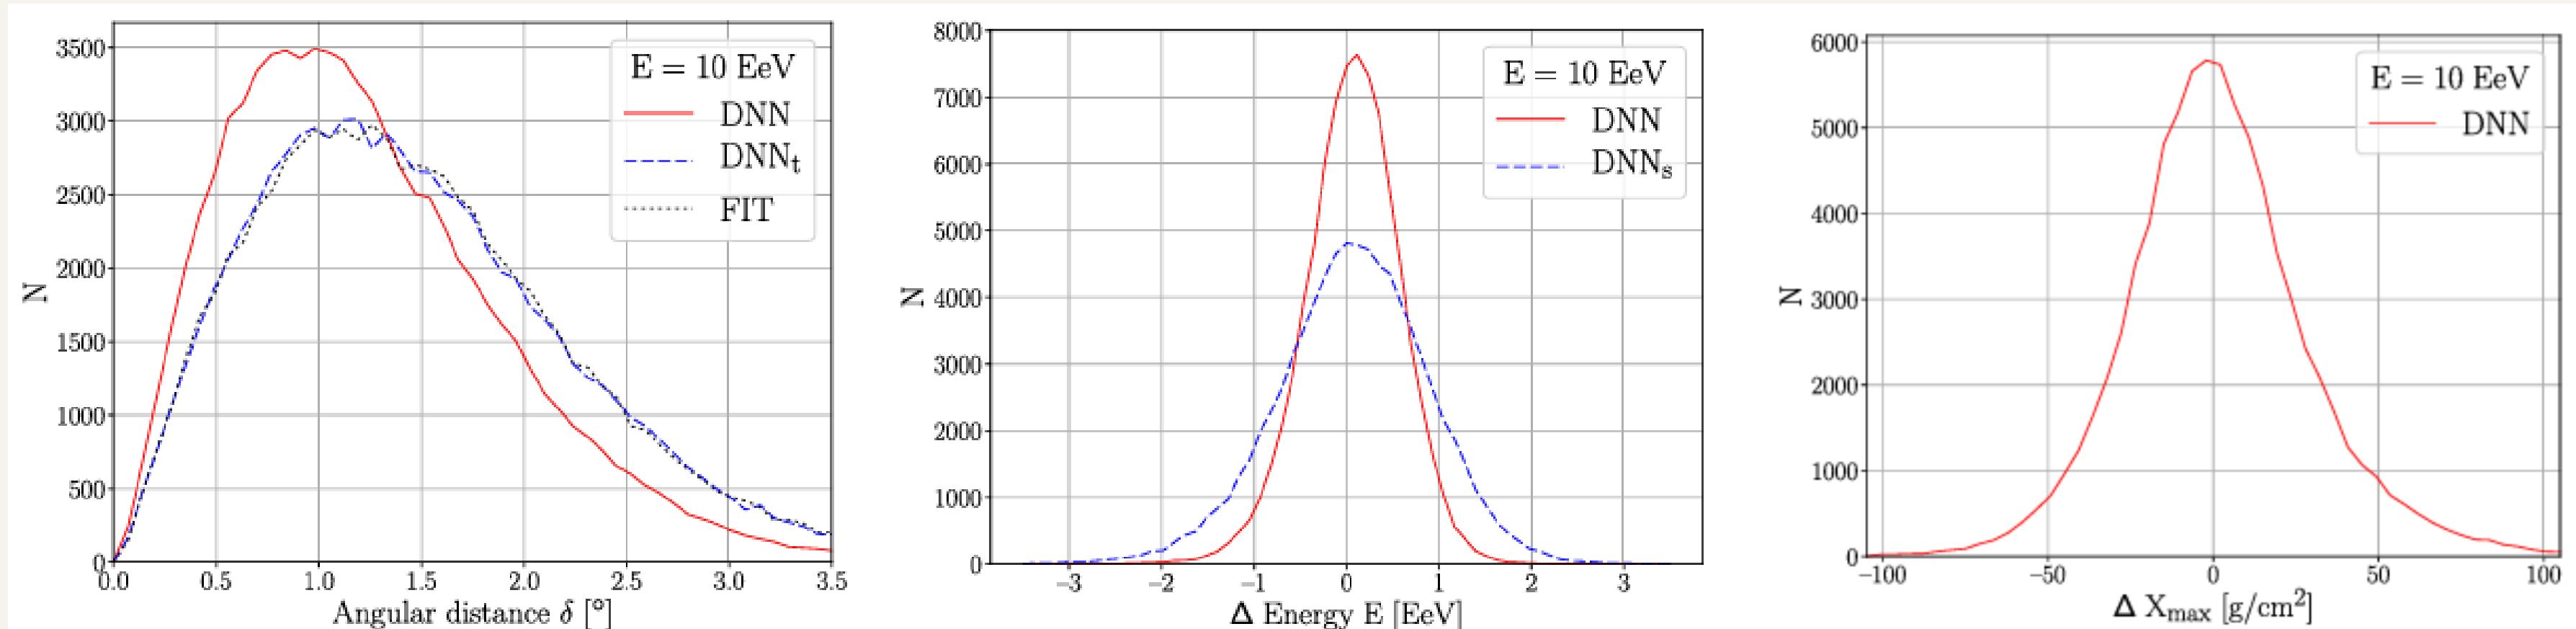


Figura 14. Densidades de error para la predicción de ángulo, energía y profundidad atmosférica máxima respectivamente obtenidas en “A deep learning-based reconstruction of cosmic ray-induced air showers” [7]. En el estudio la arquitectura se basa en capas convolucionales 3D y Separables Conv2D. Aunque los resultados parecen ser buenos (que ni tanto), las energías con las que se trabaja es excesivamente alta (10 EeV) en comparación a las que se quiere detectar en CONDOR (~GeV-TeV). Recordemos que 1 EeV = 1000000000 GeV, por tanto, este proyecto apunta a trabajar con casi 9 escalas de magnitud menos.



Estado del Arte

RECONSTRUCCIÓN DE EAS INDUCIDAS POR RAYOS CÓSMICOS

Trabajos como “Machine learning applications to energy reconstruction of gamma-ray showers for the Tibet AS y experiment.” han reconstruido eficientemente la energía de duchas de partículas generadas por rayos gamma en el rango de los TeV-PeV usando Gradient Boosting Decision Tree [8].

Así como el anterior, existen muchos ejemplos de estudios que han reconstruido la energía de incidencia de los rayos cósmicos (en distintos rangos) y otros que identifican los tipos de rayos cósmicos (separación de eventos de rayos hadrónicos y gamma) [9, 10, 11].

Sin embargo, en todos los ejemplos mencionados, todos se limitan o a clasificar únicamente la energía o el tipo de partícula, mientras que si se trabaja con predicciones angulares siempre se limitan a energías muy altas (en comparación a CONDOR).

Por ello, un objetivo importante en este proyecto es desafiar la “no existencia de estado del arte” para la reconstrucción angular en bajas energías.

Resultados preliminares

RECONSTRUCCIÓN ANGULAR - 800 GEV

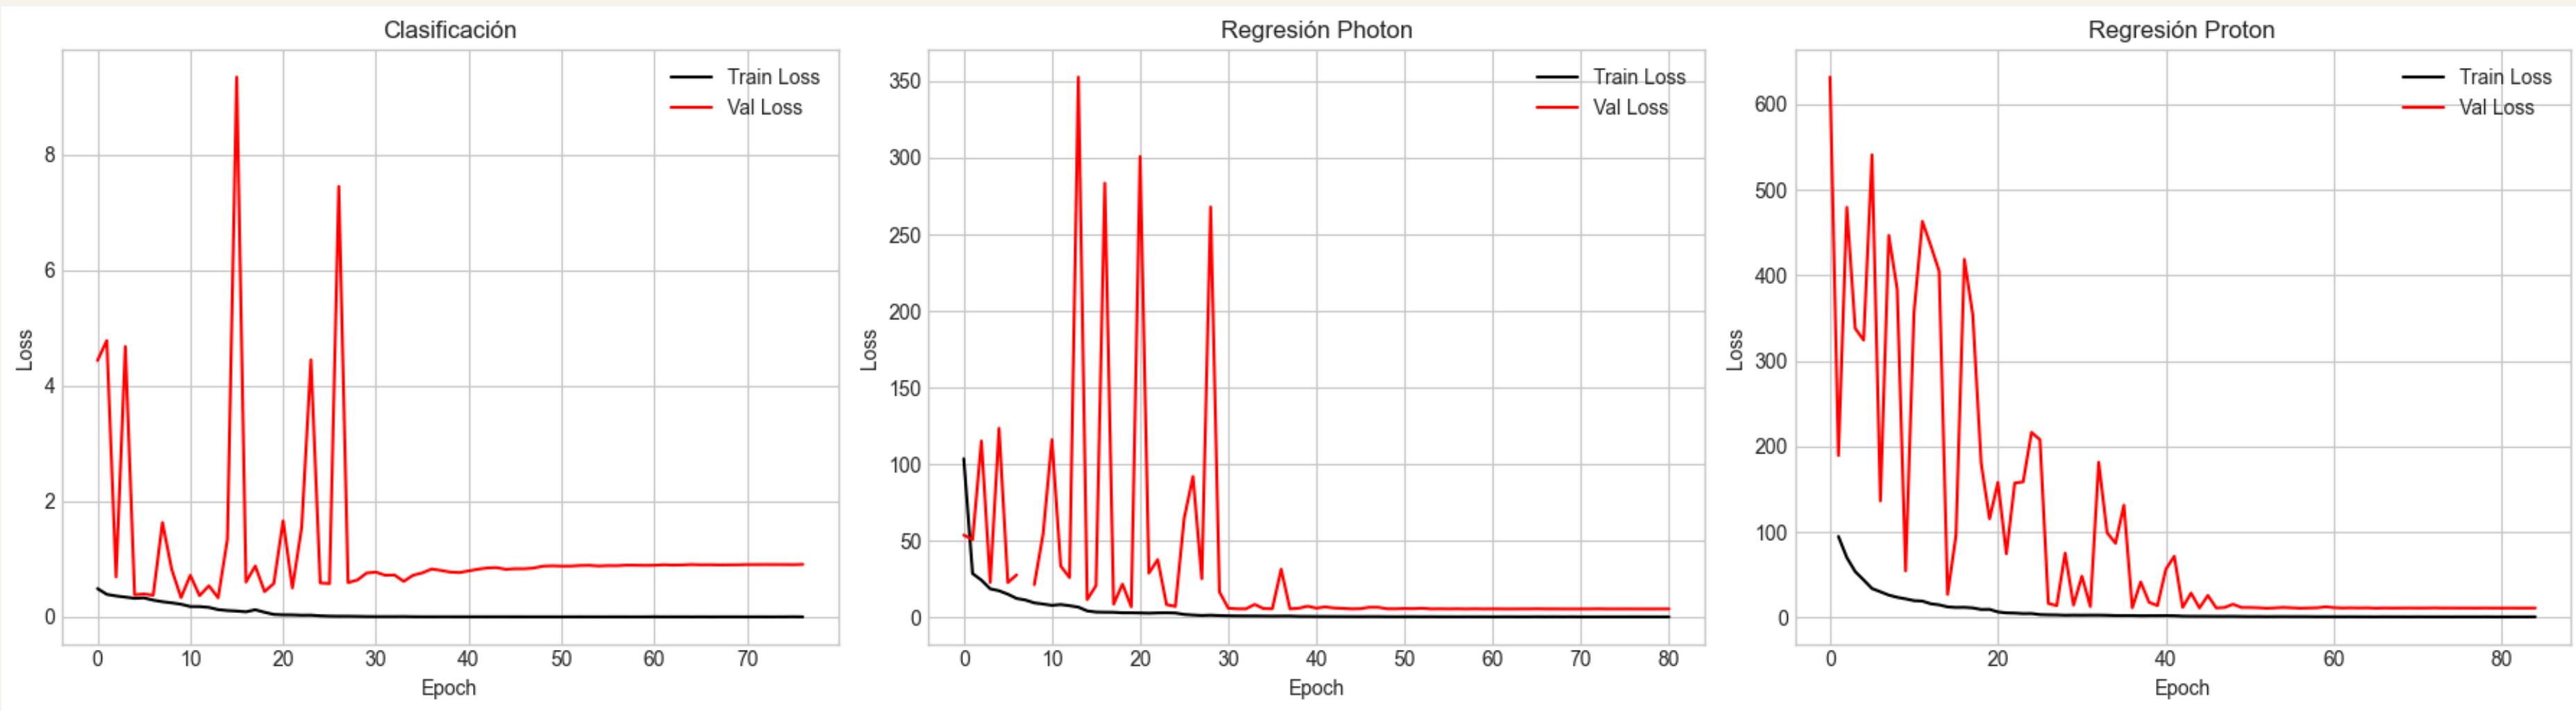


Figura 15. Gráficos de pérdida/epoch para el entrenamiento de los 3 modelos. Todo presentan una estabilidad alrededor de la época 40. La clasificación de rayos cósmicos parece tener un leve overfitting, pero igualmente los valores de pérdida son bajos, por lo que se esperan buenos resultados. Para clasificación se evalúa con la métrica **binary-crossentropy**, mientras que para regresión angular (en ambas partículas) se usa **MSE** (error cuadrático medio).

Resultados preliminares

RECONSTRUCCIÓN ANGULAR - 800 GEV

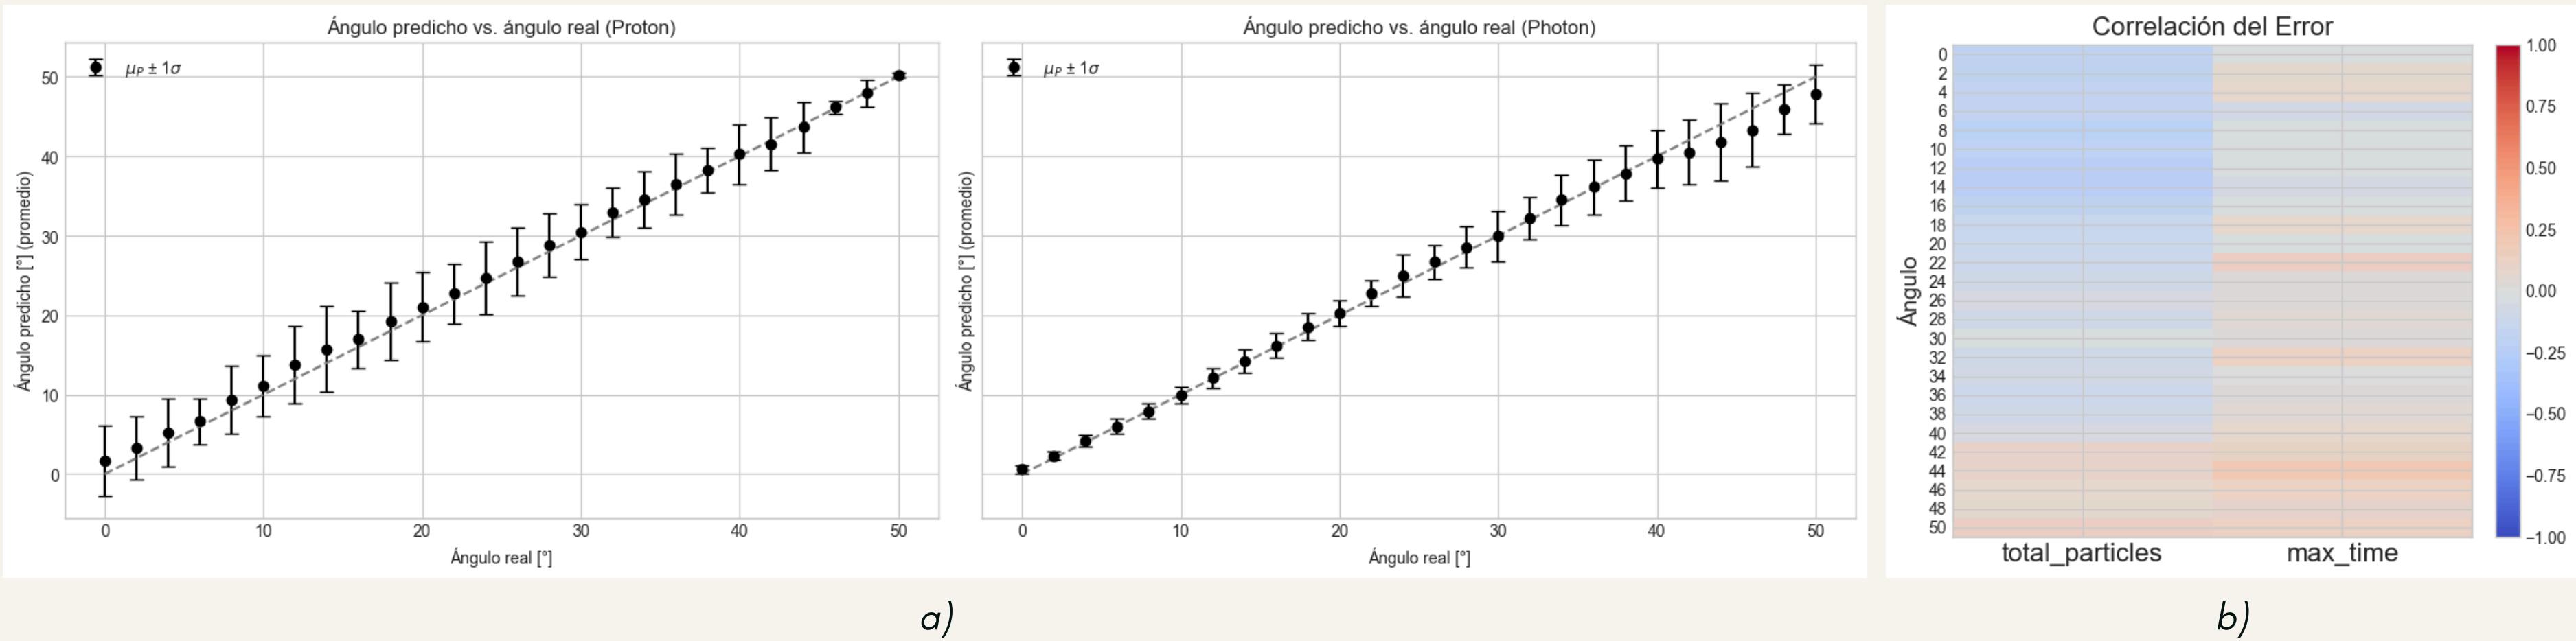


Figura 16. **a)** Reconstrucción angular para protones (izquierda) y fotones (derecha). Los puntos corresponden al promedio de las predicciones, mientras que las barras de error son la desviación estándar correspondiente a la distribución de predicciones en su respectivo ángulo. **b)** Correlación del error, por ángulo, con las variables Total de partículas y Duración Máxima de las duchas de partículas. En ángulos menores tenemos más partículas generadas (como se podía apreciar en anteriores slides), lo que se correlaciona negativamente con el error, es decir, mientras más partículas, menor error. Por su parte, la duración de las EAS parece ser no muy relevante (correlación baja) para los errores.

Resultados preliminares

RECONSTRUCCIÓN ANGULAR - 800 GEV

Además de por los gráficos vistos anteriormente, acá también podemos observar la buena capacidad del modelo para predecir los ángulos de incidencia para todo el catálogo de rangos.

Es importante notar también, que, aunque en las energías más altas (800 GeV) se soluciona el problema del sesgo, éste sigue existiendo, por lo que se puede esperar que a medida que aumenten los datos simulados, mejorarán los resultados.

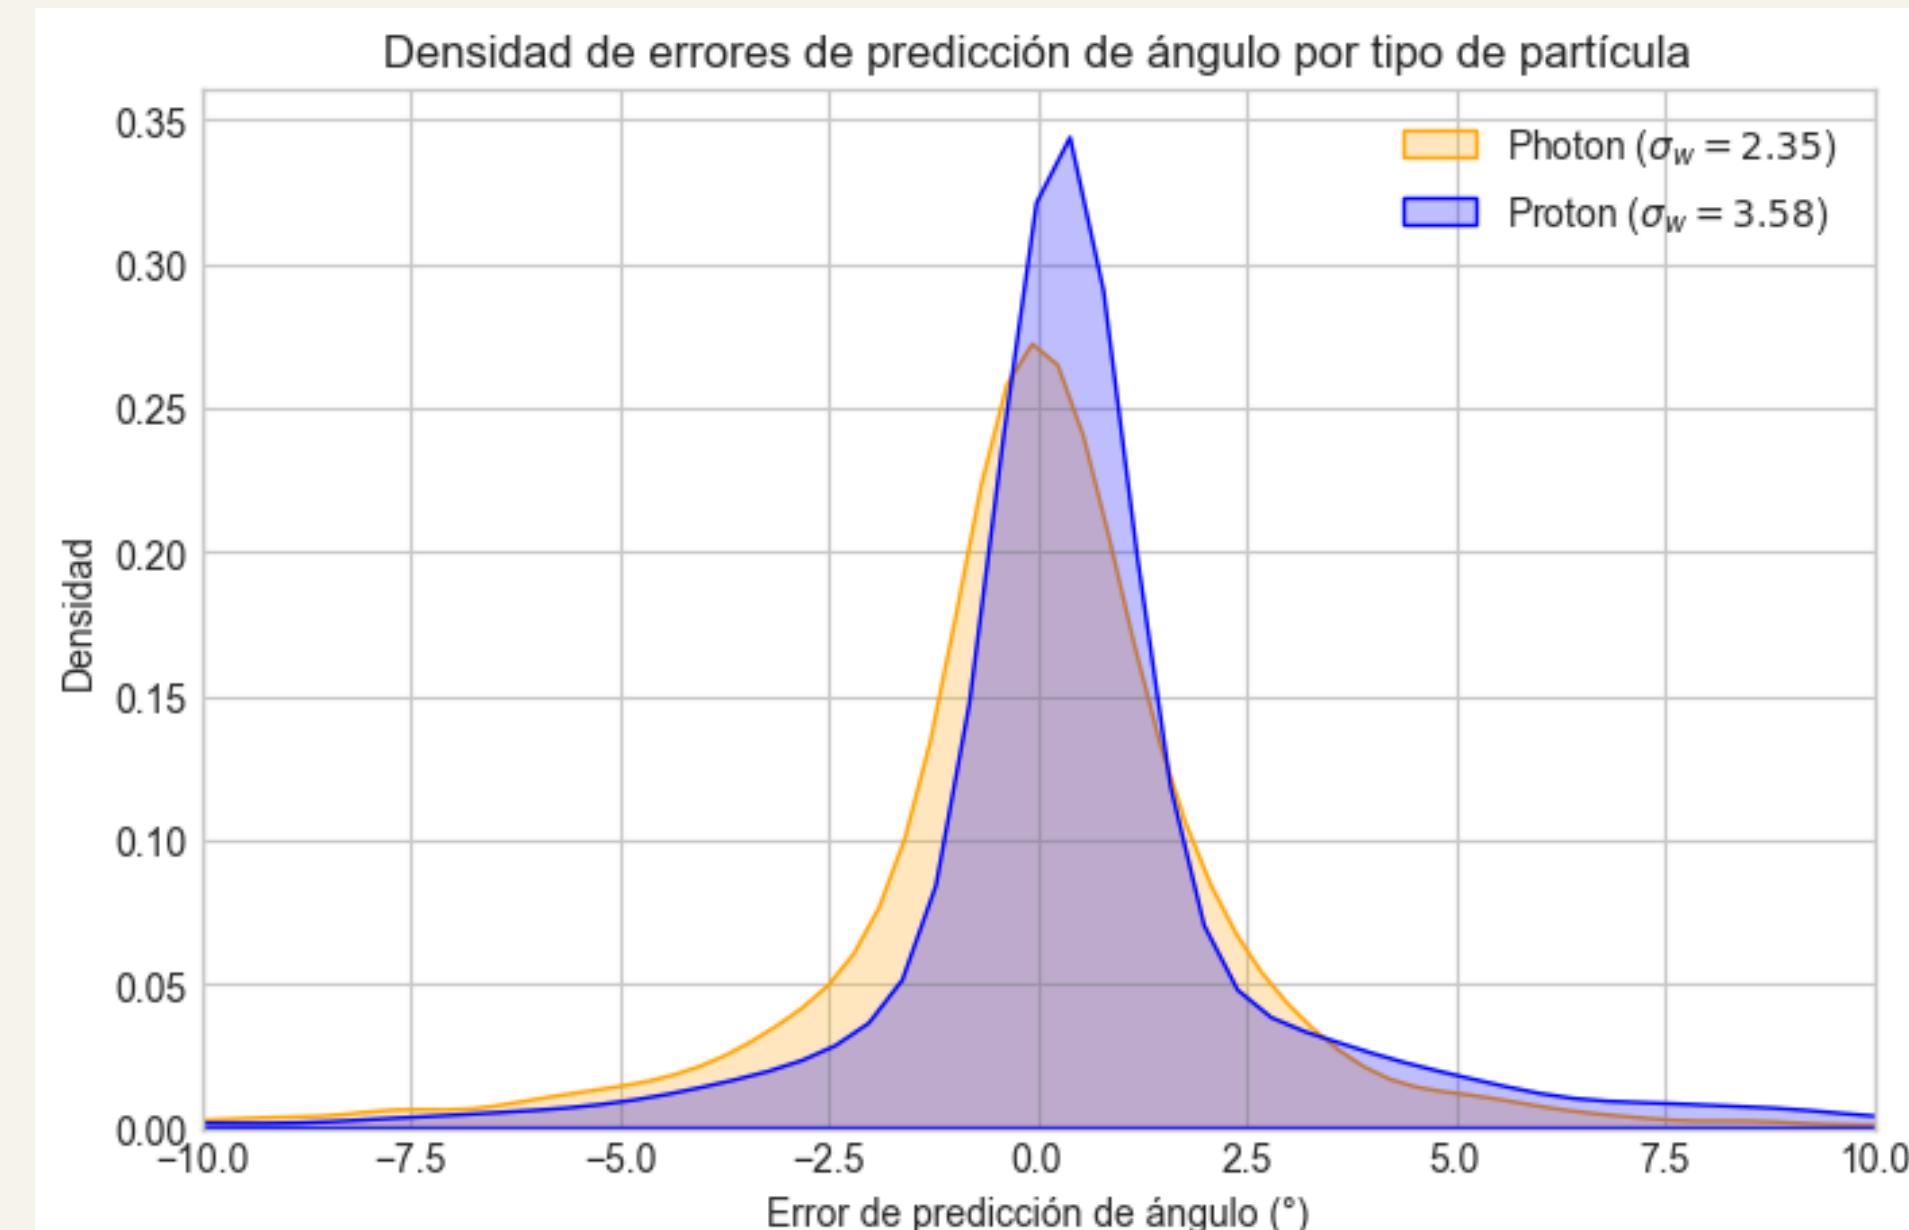


Figura 17. Densidad del error absoluto medio de predicción para la regresión angular.

Resultados preliminares

CLASIFICACIÓN DE RAYOS CÓSMICOS - 800 GEV

Buen desempeño global, aunque hay un sesgo muy leve hacia la clasificación errónea de protones como fotones.

El modelo clasifica bien entre protones y fotones a 800 GeV, con un $F1 > 0.89$ en validación. Aunque parece tender levemente al overfitting, pero no parece ser muy perjudicial en testing.

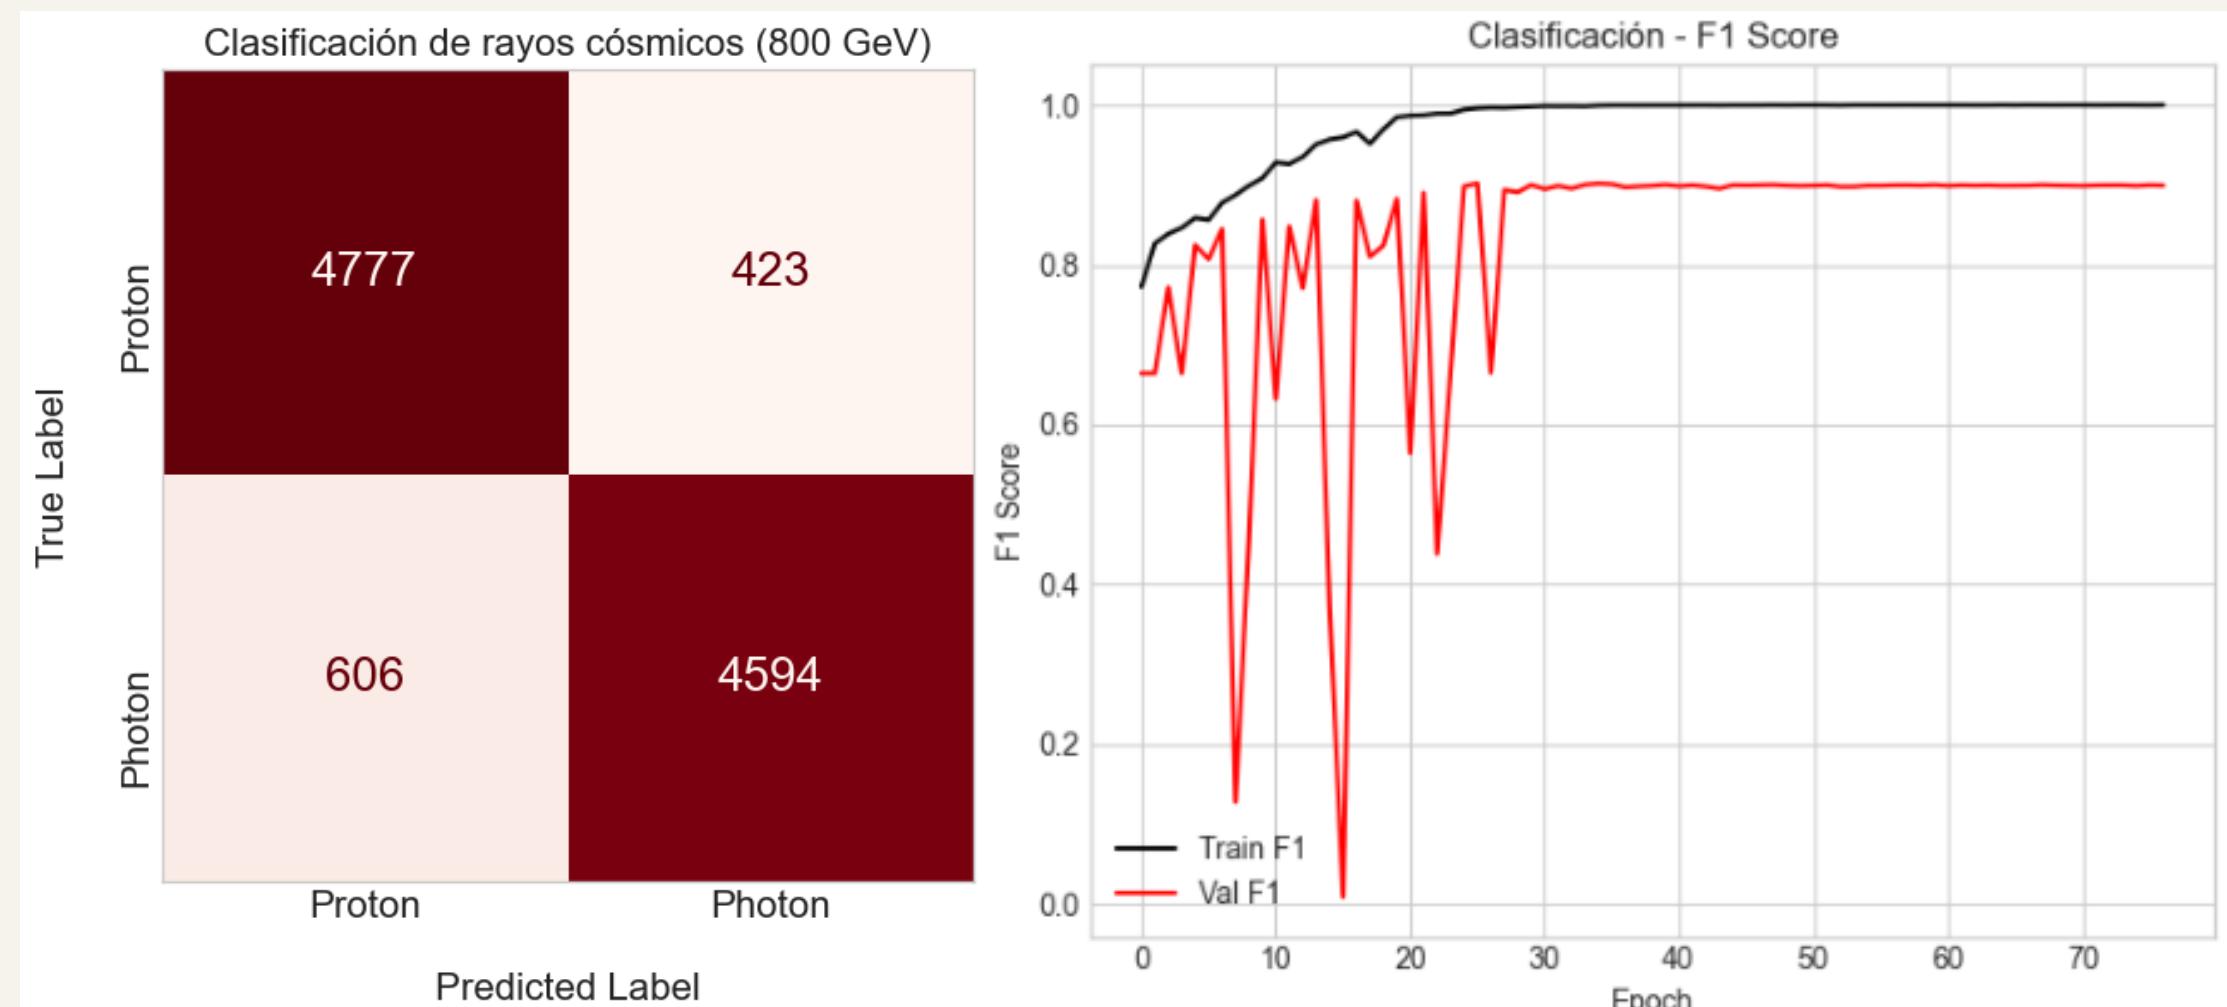
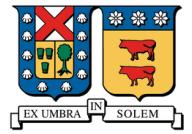


Figura 18. Matriz de confusión y gráfico pérdida/epoch para la clasificación de rayos cósmicos a 800 GeV.



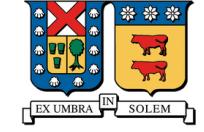
Conclusiones

- Por el momento, al trabajar en 800 GeV, el modelo puede clasificar con facilidad el tipo de partícula.
- La reconstrucción angular es precisa (aunque se dificulta un poco en ángulos mayores).
- Se espera que con un mayor número de simulaciones para energías más bajas se podrán solucionar sesgos en distribuciones y conseguir resultados más precisos.
- Dividir los modelos en 3 resulta mucho más productivo que 1 sólo que se encargue de todo, mejora la precisión en los resultados, aunque sacrificando tiempos de ejecución.
- Aunque estamos trabajando con energías muchísimo más bajas que en artículos mencionados en el estado del arte, conseguimos una reconstrucción angular más precisa, añadiendo la clasificación de rayos cósmicos.
- Un desafío interesante puede ser agregar un modelo que se encargue de clasificar energías.



Referencias

- [1] Arratia, M., Brooks, W., Huang, J., Paul, S. J., & Tapia, S. (2025). **The CONDOR Observatory: A Gamma-Ray Observatory with a 100 GeV Threshold at 5300 Meters Above Sea Level.** arXiv preprint arXiv:2503.08850.
- [2] Rao, M. V., & Sreekantan, B. V. (1998). **Extensive air showers.** World scientific.
- [3] Hamel, M. (2021). **Plastic scintillators.** Springer International Publishing.
- [4] Balagura, V., Danilov, M., Dolgoshein, B., Klemin, S., Mizuk, R., Pakhlov, P., ... & Tikhomirov, I. (2006). **Study of scintillator strip with wavelength shifting fiber and silicon photomultiplier.** Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment, 564(1), 590-596.
- [5] Heck, D., Knapp, J., Capdevielle, J. N., Schatz, G., & Thouw, T. (1998). **CORSIKA: A Monte Carlo code to simulate extensive air showers.** Report fzka, 6019(11).
- [6] Stecker, F. W. (1971). **Cosmic gamma rays** (Vol. 249). Scientific and Technical Information Office, National Aeronautics and Space Administration.
- [7] Erdmann, M., Glombitza, J., & Walz, D. (2018). **A deep learning-based reconstruction of cosmic ray-induced air showers.** Astroparticle Physics, 97, 46-53.



Referencias

- [8] Meng, Y., et al. Machine learning applications to energy reconstruction of gamma-ray showers for the Tibet AS γ experiment. *Experimental Astronomy* 59.2 (2025): 23.
- [9] Alvarado, A., Capistrán, T., Torres, I., SacahuÍ, J. R., & Alfaro, R. (2023). Cosmic-ray energy reconstruction using machine learning techniques. arXiv preprint arXiv:2310.06938.
- [10] Postnikov, E., Kryukov, A., Polyakov, S., & Zhurov, D. (2019). Deep learning for energy estimation and particle identification in gamma-ray astronomy. arXiv preprint arXiv:1907.10480.
- [11] Okukawa, S., Hara, K., Hibino, K., Katayose, Y., Kawata, K., Ohnishi, M., ... & Takita, M. (2024). Neural networks for separation of cosmic gamma rays and hadronic cosmic rays in air shower observation with a large area surface detector array. *Machine Learning: Science and Technology*, 5(2), 025016.