
Reconstrucción Angular, Inferencia de Energía y Clasificación de Rayos Cósmicos para el Observatorio CONDOR

Luis Navarro

Departamento de Informática
INF-577. Redes Neuronales Artificiales y Deep Learning Avanzado
luis.navarrof@usm.cl

Abstract

Este proyecto aborda la clasificación del tipo de partícula primaria (protón o fotón), la reconstrucción del ángulo cenital y la predicción de la energía incidente en eventos simulados para el futuro observatorio de rayos cósmicos CONDOR, ubicado en Chile. Para ello, se propone una arquitectura de red neuronal basada en capas convolucionales 1D seguidas por mecanismos de atención multi-cabeza especializados en cada tarea, capaz de procesar secuencias espacio-temporales generadas a partir de simulaciones de lluvias atmosféricas extensas realizadas con CORSIKA. El modelo trabaja con entradas de longitud variable y ha sido entrenado para aprender representaciones compartidas y específicas por tarea, logrando una predicción simultánea eficiente y robusta. Los resultados muestran un desempeño competitivo en las tres tareas, con precisiones superiores al 84% en la clasificación binaria, errores angulares promedio inferiores a 2° , y una discriminación efectiva entre niveles energéticos dentro del rango GeV. Se presentan además detalles de la arquitectura, técnicas de preprocesamiento aplicadas y las perspectivas para su validación con datos reales una vez que el detector esté en operación.

1 Introducción

El campo de la física de astropartículas busca comprender los fenómenos más energéticos del universo mediante el estudio de los rayos cósmicos – partículas de alta energía que se originan en fuentes astrofísicas (supernovas, radiación de agujeros negros, actividad solar, etc). Al entrar en la atmósfera terrestre, estos rayos cósmicos primarios interactúan con las moléculas del aire, iniciando extensas lluvias atmosféricas (EAS, por sus siglas en inglés) que comprenden una cascada de partículas secundarias que pueden ser detectadas por observatorios terrestres (Engel, Heck, and Pierog 2011; Martin, Hill, and Angel 1991). La reconstrucción precisa de las propiedades del rayo cósmico primario, como su dirección de llegada (reconstrucción angular) y su naturaleza (clasificación del tipo de rayo), es crucial para entender sus orígenes y los mecanismos que impulsan su aceleración (Bell 2013).

El Observatorio CONDOR, actualmente en desarrollo en el desierto de Atacama, a unos 5300 metros sobre el nivel del mar, está pensado para ser el observatorio de rayos cósmicos y rayos gamma de mayor altitud del planeta (Arratia et al. 2025). Ubicado en el Cerro Toco, CONDOR tiene como objetivo estudiar los rayos cósmicos en un rango de energía específico ($\sim$ GeV – TeV), complementando las capacidades de observatorios más grandes ya existentes. Los datos recolectados por CONDOR proporcionarán información valiosa sobre el flujo y la composición de los rayos cósmicos y rayos gamma.

Este proyecto aborda dos desafíos para el análisis de los datos de rayos cósmicos del futuro observatorio CONDOR: la reconstrucción precisa de la dirección de llegada de la partícula primaria, predicción

de la energía incidente del rayo cósmico y la clasificación de su tipo, centrándose en la distinción entre protones (núcleos atómicos) y fotones (rayos gamma), y en el rango de los 500 - 800 GeV. Los datos utilizados en esta investigación se generan mediante el programa CORSIKA, una herramienta útil para simular las duchas de partículas atmosféricas en detalle (Heck et al. 1998). CORSIKA permite obtener características cruciales de las EAS, como las distribuciones espacio-temporales de las partículas secundarias al impactar los detectores.

Aprovechando las técnicas de Deep Learning, proponemos una arquitectura de red neuronal híbrida que combina capas convolucionales con capas multi-atencionales para la reconstrucción angular, la inferencia energética y la clasificación del tipo de rayo cósmico a través de las características ofrecidas por las simulaciones de CORSIKA.

2 Estado del Arte - Trabajo relacionado

La aplicación de métodos de Deep Learning ha demostrado ser prometedora en la reconstrucción de las características de EAS (trayectoria, energía y profundidad atmosférica máxima) a partir de la distribución espacio-temporal de las partículas detectadas para el observatorio Pierre Auger (Erdmann, Glombitza, and Walz 2018; Allekotte et al. 2008).




Figure 1: Densidades de error para la predicción de ángulo, energía y profundidad atmosférica máxima respectivamente obtenidas en (Erdmann, Glombitza, and Walz 2018). En el estudio la arquitectura se basa en capas convolucionales 3D y Separables Conv2D. Aunque los resultados parecen ser buenos, las energías con las que se trabaja es excesivamente alta (10 EeV) en comparación a las que se quiere detectar en CONDOR ($\sim \text{GeV-TeV}$). Recordemos que $1 \text{ EeV} = 1000000000 \text{ GeV}$, por tanto, este proyecto apunta a trabajar con casi 9 escalas de magnitud menos.

Investigaciones previas también han abordado la reconstrucción teórica del ángulo de incidencia de los rayos cósmicos, un parámetro fundamental para rastrear la posible ubicación de sus fuentes astrofísicas (Dzhappuev et al. 2010; Golup et al. 2009). Adicionalmente, se han explorado técnicas tradicionales para la reconstrucción de la energía de los rayos cósmicos incidentes (Welling, Glaser, and Nelles 2019).

Trabajos como (Meng et al. 2025) han reconstruido eficientemente la energía de duchas de partículas generadas por rayos gamma en el rango de los TeV-PeV usando Gradient Boosting Decision Tree.

Así como el anterior, existen muchos ejemplos de estudios que han reconstruido la energía de incidencia de los rayos cósmicos (en distintos rangos) y otros que identifican los tipos de rayos cósmicos (separación de eventos de rayos hadrónicos y gamma) (Postnikov et al. 2019; Alvarado et al. 2023; Okukawa et al. 2024).

Sin embargo, en todos los ejemplos mencionados, todos se limitan o a clasificar únicamente la energía o el tipo de partícula, mientras que si se trabaja con predicciones angulares siempre se limitan a energías muy altas (en comparación a CONDOR). Por ello, un objetivo importante en este proyecto es desafiar la “no existencia de estado del arte” para la reconstrucción angular en bajas energías.

En general, la reconstrucción angular específicamente a partir de datos de distribución simulada para observatorios terrestres, y particularmente la clasificación de partículas primarias (como protones y fotones) utilizando Deep Learning en el contexto de dichos observatorios, representa un campo de investigación relativamente emergente. El proyecto del observatorio CONDOR, donde colaboran la Universidad Técnica Federico Santa María, el CCTVal, la Universidad de California en Riverside y otras instituciones, se encuentra a la vanguardia de estos estudios. El objetivo principal entonces

es mejorar significativamente las capacidades de detección y análisis de CONDOR mediante la aplicación de técnicas avanzadas de Deep Learning para la reconstrucción angular y la clasificación de rayos cósmicos.

3 Propuesta de solución - Materiales y métodos

3.1 Datos de Simulaciones de EAS

Para que los datos de las simulaciones CORSIKA sean realistas y se adapten al tipo de modelos que queremos utilizar, es necesario aplicar una serie de pasos para generarlos, leerlos y procesarlos adecuadamente:

1. Generar 1000 simulaciones CORSIKA por ángulo y energía, desde 0° hasta 60° en pasos de 2° , utilizando protón y fotón como partículas primarias y considerando diferentes energías incidentes (por ejemplo, 500 GeV y 800 GeV). Esto produce archivos binarios en formato DAT con toda la información de las duchas de partículas para sus respectivos parámetros de entrada (partícula primaria, energía, ángulo, altitud del detector, campo magnético, etc.).
2. Leer y traducir los archivos de simulación en formato DAT con la librería corsika-panama (Ludwig 2020), convirtiendo los datos a un formato de dataframe de la librería Pandas (McKinney et al. 2011).
3. Filtrar las partículas secundarias relevantes (eliminando aquellas que no pueden ser detectadas por el observatorio, como fotones o partículas neutras).
4. Filtrar las partículas que impactan en el área del detector CONDOR (truncando el espacio de la simulación al área hipotética de CONDOR de 122×113 metros aproximadamente).
5. Organizar los datos en secuencias temporales de bins espacio-temporales, incluyendo posición en x_{bin} , y_{bin} y los tiempos de llegada t_{bin} .
6. Filtrar aquellas simulaciones que no generaron un mínimo de 30 partículas, ya que simulaciones con muy pocas partículas suelen corresponder a eventos poco informativos o a energías demasiado bajas para alcanzar el detector, generando ruido en el análisis.
7. Realizar oversampling/undersampling para igualar el número de muestras por ángulo, energía y tipo de partícula, esto a través de un *binning* angular, es decir, crear intervalos (o bins) de ángulos, lo que permite agrupar los eventos por rangos de ángulo en vez de por valores exactos. Esto ayuda a tener un balance más fino y controlado. Para cada grupo, si hay menos muestras que el objetivo, se repiten aleatoriamente hasta alcanzar el target; si hay más, se seleccionan aleatoriamente. Esto asegura que el conjunto de datos esté balanceado y que el modelo no esté sesgado hacia ninguna combinación específica.
8. Separar los datos en conjuntos de entrenamiento, validación y test de manera estratificada.
9. Normalizar las secuencias y rellenar con ceros (padding) para que todas tengan la misma longitud.

La Figura 2 ilustra ejemplos de secuencias para diferentes combinaciones de energía, ángulo y tipo de partícula. Se observa que, a medida que aumenta el ángulo de incidencia, disminuye la cantidad de partículas detectadas, ya que el trayecto atmosférico es mayor y la cascada se dispersa más, reduciendo la eficiencia de detección en un arreglo terrestre y plano como CONDOR. Además, el alargamiento de la distribución en el eje x se incrementa con el ángulo, coherente con el desarrollo más inclinado de la ducha, y el centro de la distribución se desplaza hacia valores positivos de x , indicando la llegada oblicua del frente de la ducha.

El gradiente temporal en los tiempos de llegada también se vuelve más pronunciado a mayor ángulo, reflejando una dispersión temporal más amplia. Al comparar los tipos de partículas, los fotones presentan distribuciones más difusas y caóticas, incluso en ángulos bajos, con gradientes temporales menos definidos. En contraste, los protones generan estructuras más compactas y coherentes, con gradientes temporales más limpios, lo que sugiere un frente de ducha más regular. Toda esta información será utilizada por el modelo para mejorar la predicción tanto del ángulo como de la energía de los eventos.




Figure 2: Distribuciones espaciales (x, y) de las partículas detectadas en simulaciones de lluvias atmosféricas extensas (EAS), coloreadas según el tiempo de llegada t_{bin} en nanosegundos. Se muestran ejemplos para protones y fotones incidentes a energías de 500 GeV y 800 GeV, a distintos ángulos cenitales entre 0° y 50° . Se observa cómo el patrón espacial se desplaza y se alarga con el aumento del ángulo, y cómo las partículas tienden a llegar más tarde en los bordes del detector a medida que el ángulo crece. Estas diferencias en las distribuciones temporales y espaciales son clave para la clasificación de la partícula primaria y la reconstrucción del ángulo de incidencia.

3.2 Arquitectura de la Red Neuronal

La arquitectura actual del modelo multitarea, resumida en la Tabla 1, combina una serie de bloques convolucionales 1D con mecanismos de atención multi-cabeza para capturar representaciones espaciales y temporales complejas en las secuencias de partículas detectadas. La entrada consiste en secuencias de longitud variable, paddeadas a un máximo definido (`maxlen`), con tres características por paso temporal: posiciones espaciales discretizadas (x_{bin} , y_{bin}) y tiempo (t_{bin}). La capa `Masking` se utiliza para ignorar los valores agregados por padding durante el procesamiento.

El modelo inicia con cinco bloques convolucionales secuenciales, donde el número de filtros aumenta progresivamente (32, 64, 128, 256 y 512). Cada bloque incluye una capa `Conv1D` seguida de `max pooling` y `batch normalization`, permitiendo extraer características robustas y estables que resumen la estructura espacio-temporal de las duchas extensas de partículas (Gholamalinezhad and Khosravi 2020).

Tras esta etapa de extracción de features, la salida se bifurca en tres ramas paralelas, cada una dedicada a una tarea específica: clasificación binaria del tipo de partícula primaria (protón/fotón), clasificación binaria de energía y regresión del ángulo cenital. Cada rama incorpora un bloque de atención multi-cabeza (3 cabezas) que modela dependencias de largo alcance dentro de la secuencia, seguido de un `stack` denso con operaciones de normalización y sumas residuales para estabilizar el aprendizaje. Finalmente, una capa de `pooling` global reduce la dimensión temporal y se aplican `dropout` y `batch normalization` para evitar sobreajuste. Las salidas son capas densas con activación sigmoide para las tareas de clasificación y activación lineal para la regresión.

La optimización del modelo se realizó con Keras Tuner, explorando hiperparámetros clave como número de filtros, tamaño de kernels, cantidad de cabezas en atención, dimensiones de capas densas, tasas de `dropout` y tasa de aprendizaje, buscando minimizar una función de pérdida combinada que integra entropía cruzada para las clasificaciones y error cuadrático medio para la regresión (Pon and KK 2021). El modelo entrenable posee aproximadamente 3.46 millones de parámetros, balanceando capacidad y eficiencia computacional.

Table 1: Resumen de la arquitectura del modelo multitarea CNN + Atención Multi-Cabeza. Las secuencias de entrada tienen longitud variable y se paddean a un máximo maxlen .

Layer (Type)	Output Shape	Parameters
InputLayer	(maxlen, 3)	0
Masking	(maxlen, 3)	0
Bloques Convolucionales (Extracción de features)		
Conv1D (32) + MaxPooling1D + BatchNorm	(maxlen/2, 32)	256
Conv1D (64) + MaxPooling1D + BatchNorm	(maxlen/4, 64)	4,288
Conv1D (128) + MaxPooling1D + BatchNorm	(maxlen/8, 128)	33,280
Conv1D (256) + MaxPooling1D + BatchNorm	(maxlen/16, 256)	196,864
Conv1D (512) + MaxPooling1D + BatchNorm	(maxlen/32, 512)	787,968
Ramas de Atención (una por tarea)		
- MultiHeadAttention (3 heads, class)	(maxlen/32, 512)	393,984
Dense stack (128→512) + Add + Norm	(maxlen/32, 512)	134,400
GlobalAvgPool + Dropout + BatchNorm	(512)	4,096
Dense(512) + Sigmoid (Salida: Particle)	(1)	263,169
- MultiHeadAttention (3 heads, energy)	(maxlen/32, 512)	393,984
Dense stack (128→512) + Add + Norm	(maxlen/32, 512)	134,400
GlobalAvgPool + Dropout + BatchNorm	(512)	4,096
Dense(256) + Sigmoid (Salida: Energy)	(1)	131,329
- MultiHeadAttention (3 heads, angle)	(maxlen/32, 512)	393,984
Dense stack (128→512) + Add + Norm	(maxlen/32, 512)	134,400
GlobalAvgPool + Dropout + BatchNorm	(512)	4,096
Dense(256) + Linear (Salida: Angle)	(1)	131,329
Total Parameters		3,460,123
Trainable Parameters		3,456,091
Non-trainable Parameters		4,032

Para mejorar el rendimiento y la estabilidad del entrenamiento, se emplean técnicas como batch normalization, dropout y aritmética de precisión mixta (Micikevicius et al. 2017). La evaluación del desempeño se realiza con métricas específicas para cada tarea: accuracy y F1-score macro para las clasificaciones, y error absoluto medio (MAE) junto a desviación estándar ponderada para la regresión angular. Además, se analiza la distribución del error angular mediante estimaciones de densidad de probabilidad (KDE), permitiendo detectar sesgos y evaluar la dispersión de las predicciones.

4 Resultados preliminares

Los resultados a presentar corresponden energías incidentes de 500 y 800 GeV, dichas energía genera la cantidad suficiente de datos (en 1000 simulaciones por ángulo) para que no haya un sesgo de datos tan pronunciado por los tipos de partícula (como sucede en energías más bajas como los 100 GeV, que hay ángulos que no llegan a cumplir las condiciones especificadas anteriormente y no alcanzan a generar datos). Con ello entonces podríamos deducir que, si conseguimos buenos resultados en energías más altas, lo único que faltaría en energías más bajas sería cantidad de datos.

4.1 Métricas y Loss vs. Epochs

La Figura 4 muestra la evolución de las métricas de entrenamiento y validación para el modelo multitarea, considerando tanto la clasificación de partícula y energía como la regresión del ángulo, en datos de rayos cósmicos primarios de distintas energías.

En los gráficos se observa que las pérdidas de entrenamiento disminuyen de manera sostenida en las tres tareas (clasificación de partícula, clasificación de energía y regresión de ángulo), mientras que las pérdidas de validación presentan mayor variabilidad, especialmente en las primeras épocas, estabilizándose posteriormente. El F1 score para la clasificación de partícula muestra una mejora progresiva tanto en entrenamiento como en validación, alcanzando valores altos y estables. Para la energía, el F1 score es más fluctuante, pero también tiende a estabilizarse. En la regresión del ángulo,




Figure 3: Distribuciones de datos por ángulo y por tipo de partícula para 500 y 800 GeV respectivamente. Puede notarse que los datos de 800 GeV tienen una mayor cantidad de muestras totales y una distribución angular más completa con una presencia más notable de protones, lo que podría ofrecer un conjunto de datos más rico y diverso para el entrenamiento del modelo en comparación con los datos de 500 GeV, donde los fotones dominan fuertemente en todos los ángulos y la cantidad de datos de por sí es mucho más baja.

el MAE disminuye rápidamente en entrenamiento y, aunque la validación es más ruidosa, finalmente ambas curvas convergen, indicando que el modelo logra generalizar razonablemente bien en las tres tareas.




Figure 4: Curvas de pérdida (Loss) y métricas de rendimiento (F1-score y MAE) para las tareas de clasificación y regresión angular durante el entrenamiento del modelo. Se muestran las pérdidas de entrenamiento y validación para la clasificación y la regresión angular (panel superior), junto con el F1-score de clasificación (inferior izquierda) y el error absoluto medio (MAE) de la regresión angular (inferior derecha) a lo largo de las épocas de entrenamiento.

Cabe destacar que el entrenamiento se realizó utilizando Early Stopping, un mecanismo de parada anticipada que detiene el proceso cuando no se observa mejora en el conjunto de validación, previniendo así el sobreajuste y asegurando la consistencia de los resultados (Ji, Li, and Telgarsky 2021; Bernico 2018).

4.2 Reconstrucción angular

La Figura 5 presenta diagramas de dispersión que comparan el ángulo predicho con el ángulo real para protones y fotones, en dos energías distintas (500 y 800 GeV). Cada punto representa el promedio del ángulo predicho para un ángulo de incidencia real específico, acompañado de barras de error que corresponden a la desviación estándar ($\mu \pm 1\sigma$) de las predicciones en ese ángulo. En todos los casos, los ángulos predichos se alinean estrechamente con la línea de correlación ideal 1:1 (línea discontinua gris), lo que evidencia una alta precisión y ausencia de sesgo sistemático a lo largo de todo el rango angular (0° a 50°). Las barras de error son pequeñas y consistentes, lo que indica que

el modelo mantiene una buena precisión y baja dispersión en sus predicciones, tanto para protones como para fotones y en ambas energías.




Figure 5: Ángulo predicho vs. ángulo real para la reconstrucción angular de Protones (izquierda) y Fotones (derecha) para 500 GeV (abajo) y 800 GeV (arriba). Cada punto representa el promedio del ángulo predicho para un ángulo de incidencia real, con las barras de error indicando una desviación estándar ($\mu \pm 1\sigma$).

La Figura 6 muestra la densidad de probabilidad de los errores de predicción angular para fotones y protones, también diferenciando por energía. Las distribuciones de error están fuertemente centradas en 0° , lo que indica que la mayoría de las predicciones presentan errores muy pequeños. Ambas distribuciones son aproximadamente simétricas y de forma gaussiana, con desviaciones estándar (σ_w) muy similares entre tipos de partícula y energías (aunque mucho mejor para los fotones en 800 GeV), lo que refuerza la consistencia del modelo en la reconstrucción angular, independientemente de la naturaleza o energía de la partícula primaria.




Figure 6: Densidad de probabilidad de los errores de predicción angular para protones y fotones, diferenciando por energía (500 y 800 GeV). Las distribuciones están centradas en cero y presentan desviaciones estándar similares, lo que indica que el modelo logra errores bajos y consistentes en la reconstrucción angular, independientemente del tipo de partícula o energía.

Es importante distinguir entre la desviación estándar ponderada (σ_w) y el error absoluto medio (MAE), ya que capturan diferentes aspectos del desempeño del modelo. El MAE mide la diferencia

absoluta promedio entre los ángulos predichos y los reales, reflejando la precisión global, mientras que σ_w describe la dispersión de las predicciones alrededor de su media para cada ángulo verdadero, informando sobre la consistencia del modelo. Un MAE bajo con una σ_w alta sugiere predicciones centradas pero variables, mientras que un MAE alto con una σ_w baja indica predicciones consistentes pero sesgadas.

Por último, el modelo demuestra un rendimiento excelente en la reconstrucción angular tanto para protones como para fotones primarios, evidenciado por la fuerte alineación de los ángulos predichos con los ángulos reales en todo el rango, y por la distribución estrecha y centrada en cero de los errores de predicción con pequeñas desviaciones estándar para ambos tipos de partículas. Esto indica un alto grado de exactitud y precisión en la determinación de la dirección de llegada de los rayos cósmicos, independientemente de su naturaleza.

4.3 Identificación de Partículas

La Figura 7 muestra las matrices de confusión para la clasificación de rayos cósmicos, considerando tanto el conjunto general como los subconjuntos de 5E2 GeV y 8E2 GeV. En todos los casos, el modelo demuestra un rendimiento robusto en la distinción entre protones y fotones, clasificando correctamente la gran mayoría de los eventos para ambos tipos de partículas.

En el conjunto general, se observa una alta tasa de aciertos para protones (2098) y fotones (2087), con un número relativamente bajo de errores de clasificación cruzada. Al analizar por energía, el desempeño se mantiene consistente: para 500 GeV, el modelo identifica correctamente 1120 protones y 1036 fotones, mientras que para 800 GeV, acierta en 978 protones y 1051 fotones. Los errores de clasificación (fotones predichos como protones y viceversa) son bajos en ambos casos, aunque se aprecia una ligera tendencia a confundir más fotones como protones, especialmente en la energía más alta.




Figure 7: Matrices de confusión para la clasificación de rayos cósmicos en el conjunto general y en los subconjuntos de 500 GeV y 800 GeV. Se observa un alto desempeño del modelo en la distinción entre protones y fotones en ambos rangos de energía, con bajas tasas de error y una ligera tendencia a confundir más fotones como protones, especialmente a energías más altas.

Estos resultados sugieren que el modelo es capaz de discriminar eficazmente entre protones y fotones en diferentes rangos de energía, manteniendo un buen equilibrio y precisión en la clasificación, aunque persiste una leve asimetría en la dificultad de identificación, posiblemente asociada a la superposición de características entre ambos tipos de partículas.

4.4 Inferencia de Energía

La Figura 8 muestra las matrices de confusión para la predicción de la energía incidente (500 GeV y 800 GeV), tanto para el conjunto completo como separadas por tipo de partícula (protones y fotones). El modelo logra una buena capacidad de discriminación entre los dos niveles de energía, con una mayoría de eventos correctamente clasificados en ambas clases.

En el conjunto general, se observa que 1739 eventos de 500 GeV y 1665 de 800 GeV son correctamente identificados, mientras que los errores de clasificación (712 y 784, respectivamente) se mantienen en valores moderados. Al analizar por tipo de partícula, el desempeño es similar para




Figure 8: Matrices de confusión para la predicción de la energía incidente (500 GeV y 800 GeV), mostrando los resultados para el conjunto completo, así como para protones y fotones por separado. El modelo logra una buena discriminación entre los dos niveles de energía en ambos tipos de partículas, con tasas de acierto elevadas y errores de clasificación moderados y balanceados.

protones y fotones: para protones, 981 eventos de 500 GeV y 831 de 800 GeV son correctamente clasificados, y para fotones, 758 de 500 GeV y 834 de 800 GeV. Los errores de confusión entre energías son comparables en ambos casos, lo que indica que el modelo no presenta un sesgo significativo hacia un tipo de partícula.

Estos resultados sugieren que el modelo es capaz de distinguir de manera efectiva entre los dos niveles de energía, tanto para protones como para fotones, aunque existe cierta superposición en las características que puede llevar a errores de clasificación, especialmente en eventos cercanos al umbral entre ambas energías.

4.5 Análisis de Resultados

La Tabla 2 muestra los resultados generales del modelo para ambas tareas: la clasificación del tipo de partícula incidente y la reconstrucción del ángulo cenital. Se observa un rendimiento equilibrado entre las clases, con valores de precisión, recall y F1-score cercanos a 0.85 tanto para protones como para fotones, lo cual indica que el modelo logra una buena discriminación sin evidenciar un sesgo significativo hacia alguna de las dos categorías. Además, la exactitud global de aproximadamente 0.849 respalda la consistencia del desempeño en términos agregados.

Table 2: Métricas de rendimiento del modelo para clasificación de partículas y reconstrucción angular

Métrica	Protón	Fotón	500 GeV	800 GeV	Error Angular (°)
Precision	0.841	0.859	0.678	0.703	—
Recall	0.863	0.836	0.722	0.657	—
F1-score	0.852	0.847	0.699	0.679	—
Accuracy	0.849	0.849	0.689	0.689	—
MAE	—	—	—	—	1.572
σ_w	—	—	—	—	2.325

Respecto a la regresión angular, se reporta un error medio absoluto (MAE) de 1.57 grados, con una desviación estándar (σ_w) de 2.32 grados, lo que refleja una capacidad razonable del modelo para estimar el ángulo cenital de la partícula primaria a partir de la distribución espacio-temporal de los eventos. Estos resultados son alentadores, considerando la variabilidad natural de los datos y la complejidad del fenómeno físico modelado.

En conjunto, los valores presentados en la Tabla 2 validan el enfoque híbrido utilizado, basado en una arquitectura CNN-transformer, capaz de capturar tanto relaciones locales como patrones globales en las secuencias temporales. No obstante, se identifican oportunidades de mejora, particularmente en la reducción de la dispersión del error angular y en la robustez del modelo frente a secuencias con bajo conteo de partículas, típicas de eventos de baja energía o ángulos extremos. La incorporación

de mecanismos de atención especializados y técnicas de regularización podrían contribuir a reforzar estos aspectos en trabajos futuros.

5 Conclusión y trabajo a futuro

Este proyecto ha demostrado la efectividad del aprendizaje profundo multitarea para abordar simultáneamente tres tareas esenciales en el análisis de eventos cósmicos detectados por CONDOR: la clasificación del tipo de partícula, la estimación de su energía incidente y la reconstrucción de su ángulo cenital. La arquitectura propuesta combina una pila de capas convolucionales 1D para extracción de características con mecanismos de atención multi-cabeza especializados en cada tarea, lo que permite capturar tanto patrones locales como dependencias de más alto nivel en las secuencias de entrada.

Los resultados obtenidos para eventos simulados a energías de 500 y 800 GeV muestran un rendimiento competitivo en las tres salidas. El modelo alcanza una precisión cercana al 90% en la clasificación protón/fotón, diferenciando además de forma efectiva los niveles energéticos dentro de cada tipo de partícula. En la regresión angular, se alcanza un error medio absoluto de 1.57° y una desviación estándar de 2.32° , sin sesgos sistemáticos aparentes, como lo indican las distribuciones de error centradas en cero.

La arquitectura, con aproximadamente 3.46 millones de parámetros entrenables, fue optimizada para mantener un equilibrio entre capacidad de representación y eficiencia computacional. Las técnicas de regularización empleadas —incluyendo dropout, normalización por lotes y enmascaramiento de padding— han contribuido a la estabilidad y generalización del modelo en datos no vistos. Además, el diseño con ramas independientes para cada tarea permite una especialización eficaz sin sacrificar el aprendizaje compartido de las primeras capas.

Como líneas futuras, se plantea:

- **Extender el rango energético cubierto:** Especialmente hacia energías más bajas, donde la cantidad de partículas detectadas disminuye y la información disponible por evento es más escasa.
- **Reducir el padding innecesario:** Mediante técnicas de representación más eficientes o padding dinámico que preserve mejor la estructura física de cada evento.
- **Incorporar análisis de interpretabilidad:** Para entender qué patrones espacio-temporales son más relevantes para cada predicción y validar la coherencia física del modelo.
- **Validar con datos reales:** Una vez que el detector CONDOR esté operativo, se evaluará el modelo sobre datos experimentales, considerando efectos instrumentales y condiciones atmosféricas reales.

Para finalizar, este trabajo sienta una base sólida para el uso de modelos de deep learning multitarea en física de astropartículas, y abre el camino hacia el análisis automatizado, rápido y preciso de eventos cósmicos complejos en futuros observatorios.

References

- [1] Ingo Allekotte et al. “The surface detector system of the Pierre Auger Observatory”. In: *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment* 586.3 (2008), pp. 409–420.
- [2] A Alvarado et al. “Cosmic-ray energy reconstruction using machine learning techniques”. In: *arXiv preprint arXiv:2310.06938* (2023).
- [3] Miguel Arratia et al. “The CONDOR Observatory: A Gamma-Ray Observatory with a 100 GeV Threshold at 5300 Meters Above Sea Level”. In: *arXiv preprint arXiv:2503.08850* (2025).
- [4] AR Bell. “Cosmic ray acceleration”. In: *Astroparticle Physics* 43 (2013), pp. 56–70.
- [5] Michael Bernico. *Deep Learning Quick Reference: Useful hacks for training and optimizing deep neural networks with TensorFlow and Keras*. Packt Publishing Ltd, 2018.
- [6] DD Dzhappuev et al. “Reconstruction of the direction of the true anisotropy of galactic cosmic rays”. In: *Astronomy letters* 36 (2010), pp. 416–421.

- [7] Ralph Engel, Dieter Heck, and Tanguy Pierog. “Extensive air showers and hadronic interactions at high energy”. In: *Annual review of nuclear and particle science* 61.1 (2011), pp. 467–489.
- [8] Martin Erdmann, Jonas Glombitza, and David Walz. “A deep learning-based reconstruction of cosmic ray-induced air showers”. In: *Astroparticle Physics* 97 (2018), pp. 46–53.
- [9] Hossein Gholamalinezhad and Hossein Khosravi. “Pooling methods in deep neural networks, a review”. In: *arXiv preprint arXiv:2009.07485* (2020).
- [10] Geraldina Golup et al. “Source position reconstruction and constraints on the galactic magnetic field from ultra-high energy cosmic rays”. In: *Astroparticle Physics* 32.5 (2009), pp. 269–277.
- [11] Dieter Heck et al. “CORSIKA: A Monte Carlo code to simulate extensive air showers”. In: *Report fzka* 6019.11 (1998).
- [12] Ziwei Ji, Justin Li, and Matus Telgarsky. “Early-stopped neural networks are consistent”. In: *Advances in Neural Information Processing Systems* 34 (2021), pp. 1805–1817.
- [13] The Ludwig. *PANAMA - Parser for Atmospheric and Neutrino Data from Air-shower Monte-carlo Applications*. <https://github.com/The-Ludwig/PANAMA>. GitHub repository. 2020.
- [14] Buddy Martin, John M Hill, and Roger Angel. “The new ground-based optical telescopes”. In: *Physics Today* 44.3 (1991), pp. 22–30.
- [15] Wes McKinney et al. “pandas: a foundational Python library for data analysis and statistics”. In: *Python for high performance and scientific computing* 14.9 (2011), pp. 1–9.
- [16] Y Meng et al. “Machine learning applications to energy reconstruction of gamma-ray showers for the Tibet AS γ experiment”. In: *Experimental Astronomy* 59.2 (2025), p. 23.
- [17] Paulius Micikevicius et al. “Mixed precision training”. In: *arXiv preprint arXiv:1710.03740* (2017).
- [18] Sousuke Okukawa et al. “Neural networks for separation of cosmic gamma rays and hadronic cosmic rays in air shower observation with a large area surface detector array”. In: *Machine Learning: Science and Technology* 5.2 (2024), p. 025016.
- [19] Mohamad Zaim Awang Pon and Krishna Prakash KK. “Hyperparameter tuning of deep learning models in keras”. In: *Sparklinglight Transactions on Artificial Intelligence and Quantum Computing (STAIQC)* 1.1 (2021), pp. 36–40.
- [20] Evgeny Postnikov et al. “Deep learning for energy estimation and particle identification in gamma-ray astronomy”. In: *arXiv preprint arXiv:1907.10480* (2019).
- [21] Christoph Welling, Christian Glaser, and Anna Nelles. “Reconstructing the cosmic-ray energy from the radio signal measured in one single station”. In: *Journal of Cosmology and Astroparticle Physics* 2019.10 (2019), p. 075.